

五一数学建模竞赛

承 诺 书

我们仔细阅读了五一数学建模竞赛的竞赛规则。我们完全明白，在竞赛开始后参赛队员不能以任何方式（包括电话、电子邮件、网上咨询等）与本队以外的任何人（包括指导教师）研究、讨论与赛题有关的问题。

我们知道，抄袭别人的成果是违反竞赛规则的，如果引用别人的成果或其它公开的资料（包括网上查到的资料），必须按照规定的参考文献的表述方式在正文引用处和参考文献中明确列出。

我们郑重承诺，严格遵守竞赛规则，以保证竞赛的公正、公平性。如有违反竞赛规则的行为，我们愿意承担由此引起的一切后果。

我们授权五一数学建模竞赛组委会，可将我们的论文以任何形式进行公开展示（包括进行网上公示，在书籍、期刊和其他媒体进行正式或非正式发表等）。

参赛题号（从 A/B/C 中选择一项填写）：_____ C _____

参赛队号：_____

参赛组别（研究生、本科、专科、高中）：_____

所属学校（学校全称）：_____

参赛队员：队员 1 姓名：_____

队员 2 姓名：_____


队员 3 姓名：_____

联系方式：Email：_____ 联系电话：_____

日期：_____ 年 _____ 月 _____ 日

（除本页外不允许出现学校及个人信息）

五一数学建模竞赛



题目： 基于多源监测数据融合的边坡三段式形变识别与滑坡预警模型

关键词：边坡预警 三段式形变 变点检测 多源数据融合 XGBoost 分阶段预测

摘 要：

边坡稳定性是水利工程、交通路网、露天矿山等领域的核心安全问题。本文针对边坡多源监测数据中噪声强、异常跳变频繁、数据缺失等问题，建立了从传感器校正、形变阶段识别、多源数据预处理、分阶段位移预测到滑坡预警的完整数学模型体系。

针对问题一，建立二次多项式回归校正模型 $\hat{y} = -0.349 + 0.880x + 8.34 \times 10^{-7}x^2$ ，对光纤位移计数据进行校正。10 折交叉验证结果表明，模型 RMSE 为 2.682 mm， R^2 达到 0.9992，MAPE 为 1.81%，校正效果稳定可靠。5 个待校正数据点的校正值分别为 5.930、15.961、73.906、108.439 和 147.287 mm。

针对问题二，采用 Savitzky-Golay 滤波结合 PELT 变点检测算法识别三段式形变阶段转换节点。提出持续性、幅度和趋势一致性三条件联合判据区分噪声跳变与真实转换。识别结果为：缓慢 → 加速转换节点位于编号 8150（2024 年 6 月 29 日），加速 → 快速转换节点位于编号 9600（2024 年 7 月 9 日）。三阶段平均速度分别为 0.257、1.768 和 6.221 mm/h，各阶段模型 R^2 均在 0.94 以上。

针对问题三，采用 sym4 小波阈值去噪和 MICE 多重插补进行数据预处理，基于 MAD 稳健 Z 分数法检测异常值，共检出 797 个单变量异常点和 75 个共同异常点。岭回归关联分析表明，深部位移对表面位移贡献最大（标准化系数 0.574），其次为孔隙水压力（0.268）和降雨量（0.239），模型 5 折 CV R^2 为 0.785。

针对问题四，建立分阶段 XGBoost 回归模型，通过特征工程构建 14 维特征向量，各阶段训练 R^2 均达 0.9999。实验集 5 个关键时间点的表面位移预测值分别为 5.622、24.630、74.577、361.733 和 376.115 mm，预测曲线呈现典型的三段式形变特征。

针对问题五，通过逐一剔除法确定最优变量组合为剔除孔隙水压力后的 5 变量组合（CV-RMSE 最小，为 357.27 mm）。基于各阶段速度统计特征构建四级预警体系：注意（2.73 mm/h）、警告（3.59 mm/h）、紧急（8.37 mm/h）、危险（10.80 mm/h），与现行地质灾害蓝黄橙红四级预警标准一致。

目录

一、 问题重述	6
1.1 问题背景	6
1.2 问题概述	6
二、 模型假设	8
三、 符号说明	9
四、 问题一的建模与求解	9
4.1 问题分析	9
4.2 模型建立	10
4.2.1 多项式回归校正模型	10
4.2.2 模型阶数选择	11
4.3 模型求解	11
4.3.1 参数估计结果	11
4.3.2 模型阶数对比	11
4.3.3 交叉验证结果	12
4.3.4 表 1.1 校正结果	13
五、 问题二的建模与求解	13
5.1 问题分析	13
5.2 模型建立	14
5.2.1 数据预处理——Savitzky-Golay 滤波	14
5.2.2 位移速率计算	14
5.2.3 PELT 变点检测算法	15
5.2.4 噪声跳变与真实转换节点的区分准则	15
5.2.5 各阶段数学模型	15
5.3 模型求解	16
5.3.1 转换节点识别结果	16
5.3.2 各阶段模型参数与检验	17
六、 问题三的建模与求解	18
6.1 问题分析	18
6.2 问题 3.1：去噪与缺失值补齐	19
6.2.1 小波阈值去噪	19
6.2.2 MICE 多重插补	19

6.3 问题 3.2: 异常值检测	20
6.3.1 单变量异常检测——MAD 稳健 Z 分数法	20
6.3.2 检测结果	20
6.3.3 共同异常点识别	21
6.4 问题 3.3: 关联分析与预测	22
6.4.1 岭回归模型	22
6.4.2 各因素贡献度评估	22
6.4.3 实验集预测	23
七、问题四的建模与求解	23
7.1 问题分析	23
7.2 模型建立	24
7.2.1 训练集阶段识别	24
7.2.2 特征工程	24
7.2.3 分阶段 XGBoost 回归模型	25
7.2.4 阶段间连续性约束	25
7.3 模型求解	25
7.3.1 训练集拟合结果	25
7.3.2 实验集预测结果	26
八、问题五的建模与求解	27
8.1 问题分析	27
8.2 问题 5.1: 最优变量组合选择	28
8.2.1 变量组合评估框架	28
8.2.2 变量组合对比结果	28
8.2.3 最优组合的物理解释	29
8.3 问题 5.2: 预警机制构建	30
8.3.1 阶段识别与速度统计	30
8.3.2 四级预警阈值设定	30
8.3.3 预警机制合理性分析	31
九、模型评价与推广	32
9.1 模型优点	32
9.2 模型不足	32
9.3 模型推广	33

参考文献	33
A 附录 文件列表	35
B 附录 核心代码	35
2.1 问题 1: 多项式回归校正	35
2.2 问题 2: PELT 变点检测	36
2.3 问题 4: 分阶段 XGBoost 预测	36

Modex Agent

一、问题重述

1.1 问题背景

边坡稳定性是水利工程、交通路网、露天矿山等关键工程领域中的核心安全问题。在地质条件、气象变化与工程扰动等多因素耦合作用下，边坡崩塌、滑坡等地质灾害频繁发生，对生命财产与基础设施安全构成严重威胁。为实现边坡灾害的精准防控，行业内已构建起“空天地”一体化多源监测体系，通过卫星遥感、无人机激光雷达和地面传感设备形成多尺度、立体化的协同监测网络，为边坡全域监测与早期预警提供了坚实的数据支撑。

边坡破坏前的位移演化通常遵循“三段式形变”规律 [1, 2]：首先经历缓慢匀速形变阶段，此时位移速度基本恒定，坡体处于缓慢稳定调整状态；随后进入加速形变阶段，位移速度显著增大，坡体进入非稳定形变状态；最终发展为快速形变阶段，位移速度急剧增大，坡体趋近整体失稳破坏。然而，受工程爆破、气候变化、电磁干扰等环境因素影响，多源监测数据普遍存在噪声强、异常跳变频繁、设备故障导致数据缺失等问题，严重制约了滑坡预警的准确性与时效性。

1.2 问题概述

本文需要依据附件提供的边坡多源监测数据，建立数学模型，完成以下五个问题的求解。

问题一要求对同一监测点的光纤位移计数据 A 进行校正，使其与基准振弦式位移计数据 B 的偏差尽可能小，并通过交叉验证给出偏差量化指标，对指定的 5 个数据点进行校正验证。

问题二要求识别位移时序数据中三段式形变阶段的转换节点，给出区分噪声跳变与真实阶段转换的核心准则，对各阶段分别建立数学模型并计算平均速度。

问题三要求对包含 5 个监测变量的时序数据进行去噪和缺失值补齐，开展异常值检测并识别共同异常点，建立数学模型定量分析各因素对表面位移的贡献程度，并对实验集进行预测。

问题四要求基于包含爆破事件的 6 维时序监测数据，建立分阶段数学模型分析并预测表面位移变化规律，对实验集数据进行表面位移预测并填写指定时间点的预测值。

问题五要求从 6 类候选变量中选取 5 类构建最优变量组合模型，以表面位移速度为预警指标构建分阶段滑坡预警机制，并解释其合理性。




图 1 整体技术路线图

本文针对上述五个问题，构建了从传感器校正、形变阶段识别、多源数据预处理、分阶段位移预测到滑坡预警的完整技术体系（图1）。问题一采用多项式回归校正模型，问题二采用 Savitzky-Golay 滤波结合 PELT 变点检测算法，问题三采用小波阈值去噪与 MICE 多重插补方法，问题四采用分阶段 XGBoost 回归模型，问题五采用逐一剔除法进行变量选择并构建四级预警体系。各问题之间存在方法论上的递进关系：问题二的阶段识别方法为问题四和问题五的分阶段建模提供了基础框架。

二、模型假设

为使问题的数学建模具有可操作性，同时保证模型结论的可靠性，本文提出以下基本假设。

(1) **传感器映射稳定性假设**。在正常工作状态下，光纤位移计（数据 A）与振弦式位移计（数据 B）对同一物理量的测量值之间存在确定性的函数映射关系，该映射关系在整个观测期内保持稳定。两种传感器均安装于同一监测点，其系统偏差主要来源于传感器零漂和安装偏差，在数月级别的观测期内可视为稳定的系统性误差。

(2) **三段式形变不可逆假设**。边坡位移时序数据遵循“缓慢匀速 → 加速 → 快速”三段式形变演化规律，各阶段之间存在明确的转换节点，且转换过程不可逆。该假设基于 Saito 蠕变理论 [1] 和大量工程实践验证，边坡一旦进入加速形变阶段，内部损伤累积不可逆转。

(3) **噪声独立性假设**。监测数据中的噪声（包括传感器噪声、电磁干扰、工程爆破引起的瞬时跳变）与边坡真实形变信号相互独立，且噪声服从零均值分布。传感器噪声主要来源于电子元件热噪声和量化误差，与被测物理量无关。

(4) **多源变量因果关联假设**。表面位移受降雨量、孔隙水压力、微震事件数、深部位移等因素的共同影响，各因素对表面位移的贡献可通过回归模型进行量化。降雨入渗导致孔隙水压力升高从而降低坡体抗滑力，微震事件反映岩体内部破裂累积，深部位移反映坡体深层变形，这些物理机制已被岩土工程理论充分论证。

(5) **训练集与实验集同分布假设**。对于问题四和问题五，训练集与实验集在对应形变阶段内，表面位移与各监测变量之间的统计关系保持一致。题目明确指出“实验集与训练集在对应阶段的表面位移变化规律一致”，为跨时间段的模型迁移提供了物理基础。

三、符号说明

本文所用主要符号及其含义如表1所示。

表 1 主要符号说明

符号	含义	单位
t	时间变量	min/h
n	数据编号（时间序列索引）	—
x	光纤位移计原始测量值（数据 A）	mm
y	振弦式位移计基准测量值（数据 B）	mm
$\hat{y}$	校正后的光纤位移计数据	mm
$d(t)$	表面位移（累计）	mm
$v(t)$	表面位移速度	mm/h
$\bar{v}_k$	第 k 阶段平均位移速度	mm/h
t_1^*, t_2^*	阶段转换节点	—
$R(t)$	降雨量	mm
$p_w(t)$	孔隙水压力	kPa
$N_s(t)$	微震事件数	次
$d_{\text{deep}}(t)$	深部位移	mm
$\kappa(t)$	干湿入渗系数	—
D_b	爆破点距离	m
Q_b	单段最大药量	kg
R^2	决定系数	—
RMSE	均方根误差	mm
MAE	平均绝对误差	mm

四、问题一的建模与求解

4.1 问题分析

问题一要求对同一边坡同一监测点的光纤位移计数据 A 进行校正，使校正后的结果与基准振弦式位移计数据 B 的偏差尽可能小。附件 1 提供了 10000 条时序数据，时间起点为 2024 年 1 月 1 日 0 时，采集频率为 10 分钟一次。

对原始数据进行探索性分析发现，数据 A 的范围为 $[0, 395.053]$ mm，数据 B 的范围为 $[0, 339.544]$ mm，两者差值的均值为 23.259 mm，标准差为 13.306 mm。进一步分

析表明，差值随位移量级增大而增大：前 25% 数据的差值均值为 6.509 mm，而后 25% 数据的差值均值达到 40.014 mm。这说明偏差并非简单的常数偏移，而是与位移量级相关的比例偏差，需要建立非线性校正模型。

本问题的求解流程如图2所示，主要包括数据探索、模型选择、参数估计、交叉验证和校正输出五个步骤。




图 2 问题一求解流程图

4.2 模型建立

4.2.1 多项式回归校正模型

基于数据探索的发现，本文建立多项式回归校正模型 [15]。设光纤位移计原始读数为 x ，校正后的估计值为 $\hat{y}$ ，则校正模型为：

$$\hat{y} = f(x) = a_0 + a_1x + a_2x^2 \quad (1)$$

其中 a_0, a_1, a_2 为待估计的回归系数。

采用最小二乘法进行参数估计，最小化残差平方和：

$$\min_{a_0, a_1, a_2} \sum_{i=1}^N [y_i - (a_0 + a_1x_i + a_2x_i^2)]^2 \quad (2)$$

将上式写成矩阵形式 $\min_a \|y - Xa\|^2$ ，其中设计矩阵 X 的第 i 行为 $(1, x_i, x_i^2)$ ，参数向量 $a = (a_0, a_1, a_2)^T$ 。由正规方程可得闭式解：

$$\hat{a} = (X^T X)^{-1} X^T y \quad (3)$$

4.2.2 模型阶数选择

为确定最优多项式阶数，本文对 $p = 1, 2, 3, 4, 5$ 阶多项式分别进行 10 折交叉验证，比较各阶数下的 RMSE 和 R^2 。偏差量化指标定义如下：

$$\text{MAE} = \frac{1}{N} \sum_{i=1}^N |\hat{y}_i - y_i|, \quad \text{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (\hat{y}_i - y_i)^2} \quad (4)$$

$$R^2 = 1 - \frac{\sum_{i=1}^N (\hat{y}_i - y_i)^2}{\sum_{i=1}^N (y_i - \bar{y})^2}, \quad \text{MAPE} = \frac{100\%}{N} \sum_{i=1}^N \left| \frac{\hat{y}_i - y_i}{y_i} \right| \quad (5)$$

4.3 模型求解

4.3.1 参数估计结果

利用全部 10000 条配对数据进行最小二乘拟合，得到二次多项式回归模型的参数估计结果：

$$\hat{y} = -0.349 + 0.880x + 8.34 \times 10^{-7}x^2 \quad (6)$$

从拟合结果可以看出，一次项系数 $a_1 = 0.880$ 是主导项，表明数据 A 与数据 B 之间的偏差主要是比例偏差（斜率偏离 1 约 12%）。二次项系数 $a_2 = 8.34 \times 10^{-7}$ 极小，说明非线性效应微弱，但保留二次项可以捕捉传感器零漂随位移量级的微弱变化趋势。截距项 $a_0 = -0.349$ mm 接近零，表明在零位移处两种传感器的读数基本一致。

4.3.2 模型阶数对比

不同阶数多项式回归模型的 10 折交叉验证性能对比如表2所示。

表 2 不同阶数多项式回归模型性能对比（10 折交叉验证）

模型阶数	RMSE (mm)	MAE (mm)	R^2	MAPE (%)
线性 ($p = 1$)	2.6823	1.3081	0.9992	1.80
二次 ($p = 2$)	2.6823	1.3085	0.9992	1.81
三次 ($p = 3$)	2.6773	1.3293	0.9992	1.98
四次 ($p = 4$)	2.6772	1.3296	0.9992	1.96
五次 ($p = 5$)	2.6726	1.3318	0.9992	2.06

从表2的结果可以看出，线性模型 ($p = 1$) 的 RMSE 为 2.6823 mm， R^2 达到 0.9992，已经具有很高的拟合精度。二次模型 ($p = 2$) 的各项指标与线性模型几乎完全一致，而三次及以上模型的 RMSE 改善不超过 0.01 mm。考虑到高阶多项式存在过拟合风险且

改善极其微小，本文最终选择二次多项式模型（ $p = 2$ ），在保证拟合精度的同时兼顾模型的简洁性和可解释性。

4.3.3 交叉验证结果

采用 10 折交叉验证评估模型的泛化性能，将 10000 条数据随机打乱后均分为 10 份，每次用 9 份训练、1 份验证，循环 10 次。各折的 RMSE 和 R^2 分布如图3所示。




图 3 10 折交叉验证结果

交叉验证的结果表明模型具有优异的稳定性：10 折 RMSE 的均值为 2.682 mm，标准差仅为 0.065 mm，各折之间的波动极小。 R^2 的均值为 0.9992，标准差为 0.000044，说明模型解释了 99.92% 的数据变异。MAE 均值为 1.309 mm，MAPE 均值为 1.81%，进一步验证了校正模型在不同数据子集上的一致性表现。

校正效果的可视化对比如图4所示。




图 4 数据校正效果对比

校正前数据 A 与数据 B 之间存在明显的系统性偏差，散点偏离 $y = x$ 对角线。经过二次多项式校正后，预测值与基准值高度吻合，散点紧密分布在对角线两侧， R^2 达到 0.9992，RMSE 仅为 2.682 mm，校正效果显著。残差分析显示残差均值为 0.000 mm，Durbin-Watson 统计量为 2.009（接近 2），表明残差不存在显著的自相关性，模型假设合理。

4.3.4 表 1.1 校正结果

将校正模型应用于题目要求的 5 个待校正数据点，结果如表3所示。

表 3 问题 1 数据校正结果

	验证数据点				
	1	2	3	4	5
校正前数据 x (mm)	7.132	18.526	84.337	123.554	167.667
校正后数据 $\hat{y}$ (mm)	5.930	15.961	73.906	108.439	147.287

校正结果符合物理预期：由于光纤位移计存在约 12% 的比例偏差 ($a_1 = 0.880$)，校正后的数据均小于原始数据，且校正幅度随位移量级增大而增大。在低位移区间 ($x = 7.132$ mm)，校正量约为 1.2 mm；在高位移区间 ($x = 167.667$ mm)，校正量增大至约 20.4 mm，与数据探索阶段发现的偏差特征完全一致。

五、问题二的建模与求解

5.1 问题分析

问题二要求识别附件 2 中位移时序数据的三段式形变阶段转换节点，给出区分噪声跳变与真实阶段转换的核心准则，并对各阶段分别建立数学模型。附件 2 包含 10000 条位移时序数据，采集时刻从 2024 年 5 月 4 日 0 时起，采集频率为 10 分钟一次，时间跨度约 69.4 天。

数据探索表明，位移范围为 $[0, 1304.153]$ mm，呈现明显的三阶段递增趋势。滑动窗口速度从前段的约 0.004 mm/点逐步增至后段的约 1.17 mm/点，速度差分存在负值跳变（最小值为 -4.204 mm/点），说明数据中存在显著的噪声干扰。本问题的求解流程如图5所示。




图 5 问题二求解流程图

5.2 模型建立

5.2.1 数据预处理——Savitzky-Golay 滤波

为消除高频噪声对阶段识别的干扰，首先对原始位移时序数据进行 Savitzky-Golay 滤波。该滤波器通过在滑动窗口内进行多项式最小二乘拟合来平滑数据：

$$\tilde{d}(n) = \sum_{m=-M}^M c_m \cdot d(n+m) \quad (7)$$

其中 c_m 为滤波系数， M 为半窗口宽度。选择窗口长度 $2M+1=51$ （约 8.5 小时的数据），多项式阶数 $q=3$ 。Savitzky-Golay 滤波 [4] 相比简单移动平均的优势在于能够保持信号的趋势特征而不引入相位延迟，这对于精确定位阶段转换节点至关重要。

5.2.2 位移速率计算

对去噪后的位移数据，采用中心差分法计算位移速率：

$$v(n) = \frac{\tilde{d}(n+w/2) - \tilde{d}(n-w/2)}{w \cdot \Delta t} \quad (8)$$

其中 $w=30$ 为滑动窗口宽度（对应 5 小时）， $\Delta t=10 \text{ min}=1/6 \text{ h}$ 。采用较大的窗口宽度可以进一步平滑速率序列中的短期波动，使阶段特征更加清晰。

5.2.3 PELT 变点检测算法

在速率序列上应用 PELT (Pruned Exact Linear Time) 算法 [3] 检测均值和方差的突变点。PELT 算法的目标函数为最小化分段代价函数：

$$\min_{\tau_1, \dots, \tau_m} \sum_{i=1}^{m+1} [C(v_{\tau_{i-1}+1:\tau_i}) + \beta] \quad (9)$$

其中 C 为段内代价函数, β 为惩罚项 (采用 BIC 准则 $\beta = \log(N)$), $\tau_0 = 0 < \tau_1 < \dots < \tau_m < \tau_{m+1} = N$ 为变点序列。段内代价函数采用正态分布的负对数似然：

$$C(v_{s:e}) = (e - s) \log \hat{\sigma}_{s:e}^2 + (e - s) \quad (10)$$

其中 $\hat{\sigma}_{s:e}^2$ 为段 $[s, e]$ 内速率的样本方差。PELT 通过剪枝策略将计算复杂度从 $O(N^2)$ 降至 $O(N)$, 适用于大规模时序数据的变点检测。

5.2.4 噪声跳变与真实转换节点的区分准则

为区分噪声或工程扰动引起的瞬时跳变与真实的阶段转换节点, 本文提出三条件联合判据。

准则一——持续性准则：真实的阶段转换节点之后, 速率变化必须持续至少 $T_{\min} = 360$ 个数据点 (即 60 小时 ≈ 2.5 天)。瞬时跳变通常在数小时内恢复到趋势线附近, 而真实的阶段转换代表坡体力学状态的根本改变, 其影响是持久的。

准则二——幅度准则：转换前后的平均速率变化幅度必须超过转换前阶段速率标准差的 3 倍：

$$|\bar{v}_{\text{after}} - \bar{v}_{\text{before}}| > 3\sigma_{\text{before}} \quad (11)$$

该准则基于 3σ 原则, 在正态分布假设下对应 99.7% 的置信水平, 能够有效排除正常波动范围内的速率变化。

准则三——趋势一致性准则：转换后的速率序列应呈现单调递增趋势 (Mann-Kendall 趋势检验 $p < 0.05$ 且 $\tau > 0$), 而非随机波动。三段式形变的物理机制决定了每个阶段内的速率应保持稳定或递增, 不会出现速率先增后降的情况。

只有同时满足上述三个准则的变点才被认定为真实的阶段转换节点。

5.2.5 各阶段数学模型

根据三段式形变的物理机制, 对各阶段分别建立数学模型。

阶段 I——缓慢匀速形变采用线性模型：

$$d_I(t) = \alpha_1 t + \beta_1 + \epsilon_1(t) \quad (12)$$

其中 α_1 为匀速形变速率 (mm/h), β_1 为初始位移, $\epsilon_1 \sim N(0, \sigma_1^2)$ 。缓慢匀速阶段的位移速度基本恒定, 线性模型能够准确描述这一特征。

阶段 II——加速形变采用二次多项式模型:

$$d_{II}(t) = \alpha_2(t - t_1^*)^2 + \beta_2(t - t_1^*) + \gamma_2 + \epsilon_2(t) \quad (13)$$

其中 $\alpha_2 > 0$ 为加速度参数, β_2 为转换点处的初始速率, γ_2 为转换点处的位移值。选择二次模型而非指数模型的理由在于: 加速阶段的速度增长是渐进的, 二次模型在物理上对应匀加速运动, 参数可解释性强。

阶段 III——快速形变采用指数增长模型:

$$d_{III}(t) = A \cdot e^{\lambda(t-t_2^*)} + C + \epsilon_3(t) \quad (14)$$

其中 A 为振幅参数, $\lambda > 0$ 为指数增长率, C 为基线偏移。快速形变阶段位移速度急剧增大, 呈现典型的指数增长特征, 与 Saito 蠕变理论 [1] 中第三阶段 (加速蠕变) 的描述一致。

各阶段平均速度的计算公式为:

$$\bar{v}_k = \frac{d(t_{k,\text{end}}) - d(t_{k,\text{start}})}{t_{k,\text{end}} - t_{k,\text{start}}} \quad (\text{mm/h}) \quad (15)$$

5.3 模型求解

5.3.1 转换节点识别结果

经过 Savitzky-Golay 滤波、速率计算和 PELT 变点检测, 并通过三条件联合判据筛选, 最终识别出两个阶段转换节点:

缓慢匀速 $\rightarrow$ 加速形变的转换节点 t_1^* 位于编号 8150, 对应时间为 2024 年 6 月 29 日 14:10。加速形变 $\rightarrow$ 快速形变的转换节点 t_2^* 位于编号 9600, 对应时间为 2024 年 7 月 9 日 15:50。两个转换节点将 10000 条数据划分为三个阶段: 缓慢匀速阶段 (编号 1-8000, 约 55.6 天)、加速形变阶段 (编号 8001-9500, 约 10.4 天)、快速形变阶段 (编号 9501-10000, 约 3.5 天)。

三段式形变阶段的识别结果如图6所示。




图 6 三段式形变阶段识别结果

位移时序曲线清晰地展现了三阶段演化特征：缓慢阶段位移缓慢线性增长，加速阶段曲线开始上翘，快速阶段位移急剧攀升。两条竖直虚线标注的转换节点准确地捕捉了速率发生质变的时刻，与位移曲线的形态变化高度吻合。

5.3.2 各阶段模型参数与检验

各阶段数学模型的拟合结果如图7和表4所示。




图 7 各阶段数学模型拟合结果

表 4 三段式形变阶段识别结果汇总

形变阶段	数据编号范围	平均速度 (mm/h)	模型类型	R^2
缓慢匀速阶段	1 – 8000	0.257	线性模型	0.9447
加速形变阶段	8001 – 9500	1.768	二次多项式	0.9999
快速形变阶段	9501 – 10000	6.221	指数增长模型	1.0000

缓慢匀速阶段的线性模型 $d_t = 0.159t + 3.0$ 的 $R^2 = 0.9447$ ，RMSE 为 5.67 mm，平均速度为 0.257 mm/h。该阶段持续时间最长（约 55.6 天），位移速度基本恒定，坡体处于缓慢稳定调整状态。 R^2 未达到 0.99 的原因在于该阶段跨度较长，数据中包含较多的噪声波动，但线性趋势是明确的。

加速形变阶段的二次多项式模型 $R^2 = 0.9999$ ，RMSE 仅为 0.28 mm，拟合精度极高。平均速度为 1.768 mm/h，约为缓慢阶段的 6.9 倍，速度增长显著。该阶段持续约 10.4 天，坡体进入非稳定形变状态，位移加速度逐渐增大。

快速形变阶段的指数增长模型 $R^2 = 0.9988$ ，RMSE 为 2.72 mm。平均速度为 6.221 mm/h，约为缓慢阶段的 24.2 倍、加速阶段的 3.5 倍。该阶段仅持续约 3.5 天，但位移增量巨大，坡体趋近整体失稳破坏。指数增长模型准确捕捉了位移速度急剧增大的特征。

灵敏度分析表明，当滤波窗口在 21–101 范围内变化时，PELT 检测到的变点位置保持一致（编号 8425 和 9525 附近），说明变点检测结果对滤波参数不敏感，具有良好的鲁棒性。

六、问题三的建模与求解

6.1 问题分析

问题三提供了包含降雨量、表面位移、深部位移、孔隙水压力、微震事件数的 5 变量时序监测数据，数据中存在传感器故障和环境干扰引发的异常值与缺失值。训练集包含 10000 条数据，各变量缺失率在 4.6%–5.6% 之间；实验集包含 5000 条数据，其中表面位移全部缺失（需预测）。本问题包含三个递进的子任务：去噪与缺失值补齐（3.1）、异常值检测（3.2）、关联分析与预测（3.3）。求解流程如图8所示。




图 8 问题三求解流程图

6.2 问题 3.1：去噪与缺失值补齐

6.2.1 小波阈值去噪

对各变量的时序数据采用离散小波变换（DWT）进行去噪处理 [5, 14]。选用 sym4 小波基，分解层数 $J = 4$ ，将信号分解为近似系数和各层细节系数：

$$s(n) = \sum_k a_{J,k} \phi_{J,k}(n) + \sum_{j=1}^J \sum_k d_{j,k} \psi_{j,k}(n) \quad (16)$$

其中 $a_{J,k}$ 为近似系数， $d_{j,k}$ 为细节系数， ϕ 和 ψ 分别为尺度函数和小波函数。

对各层细节系数应用软阈值函数进行去噪：

$$\hat{d}_{j,k} = \text{sign}(d_{j,k}) \cdot \max(|d_{j,k}| - \lambda_j, 0) \quad (17)$$

通用阈值（VisuShrink）为 $\lambda_j = \sigma_j \sqrt{2 \ln N}$ ，其中噪声标准差采用 MAD 方法估计： $\sigma_j = \text{median}(|d_{j,k}|)/0.6745$ 。选择小波去噪而非简单滤波的理由在于：小波变换具有多分辨率分析能力，可同时在时域和频域进行信号分析，软阈值去噪能有效去除高频噪声同时保留信号的突变特征（如降雨事件引起的位移突增）。

6.2.2 MICE 多重插补

缺失值补齐采用 MICE（Multiple Imputation by Chained Equations）方法 [6]。设数据矩阵 $\mathbf{Z} = [R, p_w, N_s, d_{\text{deep}}, d_{\text{surf}}]$ ，对第 j 个变量的缺失值，通过迭代条件回归进行

插补：

$$Z_j^{(t+1)}|Z_{-j}^{(t)} \sim P(Z_j|Z_{-j}, \hat{\theta}_j^{(t)}) \quad (18)$$

具体步骤为：首先用各变量的中位数初始化缺失值；然后对每个含缺失值的变量 Z_j ，以其他变量 Z_{-j} 为自变量、 Z_j 的非缺失值为因变量拟合回归模型，从后验预测分布中抽样填充 Z_j 的缺失值；重复迭代直至收敛（本文设置 20 次迭代）。

选择 MICE 而非简单插值的数学依据在于：MICE 基于 Gibbs 采样原理，在迭代过程中各变量的条件分布逐步收敛到联合分布，从而保持变量间的协方差结构。数据探索发现变量间存在强相关性（如孔隙水压力与深部位移的相关系数达 0.899），为条件插补提供了良好的信息基础。

6.3 问题 3.2：异常值检测

6.3.1 单变量异常检测——MAD 稳健 Z 分数法

对预处理后的各变量数据，采用基于中位数绝对偏差（MAD）的稳健 Z 分数法进行异常值检测：

$$z_{\text{MAD},i} = \frac{0.6745 \cdot (z_{j,i} - \tilde{z}_j)}{\text{MAD}_j} \quad (19)$$

其中 $\tilde{z}_j = \text{median}(Z_j)$ ， $\text{MAD}_j = \text{median}(|Z_j - \tilde{z}_j|)$ 。系数 0.6745 使得 MAD 在正态分布下与标准差一致。当 $|z_{\text{MAD},i}| > 3$ 时，标记该数据点为异常值。

选择 MAD 而非标准 Z 分数的理由在于：MAD 对异常值具有鲁棒性（崩溃点 50%），而标准差受异常值影响大（崩溃点 0%），在监测数据普遍存在异常跳变的场景下，MAD 方法能够提供更可靠的异常检测结果。

6.3.2 检测结果

训练集单变量异常点检出结果如表5所示。

表 5 训练集单变量异常点检出结果

数据集变量	异常点数量	占比 (%)
a: 降雨量	503	5.03
b: 孔隙水压力	79	0.79
c: 微震事件数	59	0.59
d: 深部位移	63	0.63
e: 表面位移	93	0.93
总数	797	—

降雨量的异常点数量最多（503 个，占 5.03%），这与降雨量数据的分布特征密切相关：降雨量呈现典型的右偏分布，大部分时间无降雨或微量降雨，而暴雨事件会产生远超中位数的极端值，被 MAD 方法标记为异常。孔隙水压力、微震事件数和深部位移的异常点占比均不超过 1%，说明这些变量的数据质量相对较好。表面位移的异常点占比为 0.93%，主要对应传感器故障或工程扰动引起的瞬时跳变。

6.3.3 共同异常点识别

共同异常点定义为同一时间点有 2 个及以上变量同时被标记为异常：

$$\text{共同异常点} = \left\{ n : \sum_{j=1}^5 \mathbb{I}(|z_{\text{MAD},j}(n)| > 3) \geq 2 \right\} \quad (20)$$

经检测，训练集中共有 75 个共同异常点。部分共同异常点的异常变量组合如表6所示。

表 6 训练集多变量共同异常点变量清单（部分）

时间点对应编号	共同异常点处的异常变量
547	bd（孔隙水压力、深部位移）
548	bd（孔隙水压力、深部位移）
1108	ae（降雨量、表面位移）
1406	ae（降雨量、表面位移）
1632	ae（降雨量、表面位移）
2259	be（孔隙水压力、表面位移）
2260	be（孔隙水压力、表面位移）
2261	be（孔隙水压力、表面位移）
2262	be（孔隙水压力、表面位移）
3254	ce（微震事件数、表面位移）

共同异常点的变量组合揭示了边坡监测变量之间的物理耦合关系。编号 547–548 处孔隙水压力与深部位移同时异常，可能对应一次降雨入渗事件导致的坡体响应。编号 1108、1406、1632 处降雨量与表面位移同时异常，反映了强降雨对坡体表面位移的直接驱动作用。编号 2259–2262 处孔隙水压力与表面位移连续 4 个时间点同时异常，表明该时段可能发生了持续的地下水位变化事件。

灵敏度分析表明，当 MAD Z 分数阈值从 2.0 增大到 4.0 时，单变量异常点数量从 4560 降至 1872，共同异常点数量从 1067 降至 58。本文选择阈值 3.0 作为折中方案，在检出率和误报率之间取得平衡。

6.4 问题 3.3：关联分析与预测

6.4.1 岭回归模型

基于预处理后的训练集数据，建立多元线性回归模型定量分析各因素对表面位移的贡献：

$$d_{\text{surf}} = \beta_0 + \beta_1 R + \beta_2 p_w + \beta_3 N_s + \beta_4 d_{\text{deep}} + \epsilon \quad (21)$$

由于孔隙水压力与深部位移之间存在强共线性（ $r = 0.899$ ），采用岭回归（L2 正则化）缓解多重共线性问题：

$$\hat{\beta}_{\text{ridge}} = \arg \min_{\beta} \left\{ \sum_{i=1}^N (d_{\text{surf},i} - \mathbf{x}_i^T \beta)^2 + \lambda \sum_{j=1}^4 \beta_j^2 \right\} \quad (22)$$

闭式解为 $\hat{\beta}_{\text{ridge}} = (\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^T \mathbf{d}_{\text{surf}}$ ，正则化参数 λ 通过 5 折交叉验证选择，最优值为 $\lambda = 59.64$ 。

6.4.2 各因素贡献度评估

通过标准化回归系数 $\beta_j^{\text{std}} = \beta_j \cdot \sigma_{x_j} / \sigma_{d_{\text{surf}}}$ 评估各因素的贡献度，并辅以随机森林特征重要性进行交叉验证。关联分析结果如图9所示。




图 9 关联分析结果

深部位移对表面位移的贡献最大，标准化回归系数为 0.574，随机森林重要性达 75.7%。这一结果具有明确的物理意义：深部位移直接反映了坡体深层的变形状态，与表面位移之间存在最直接的力学传递关系。孔隙水压力的标准化系数为 0.268，排名第二，其物理机制在于孔隙水压力升高会降低岩土体颗粒间的有效接触应力，从而减小坡体的抗滑能力。降雨量（0.239）和微震事件数（0.193）的贡献相对较小，但仍具有统计显著性。

岭回归模型的 5 折交叉验证 R^2 为 0.785 ± 0.018 , RMSE 为 1.673 ± 0.108 mm, 说明四个监测变量能够解释表面位移约 78.5% 的变异。剩余 21.5% 的变异可能来源于未观测的因素（如温度变化、地质构造活动等）以及模型的线性假设限制。

6.4.3 实验集预测

将训练集建立的岭回归模型应用于实验集, 对表面位移进行预测。预测结果的散点图如图10所示。




图 10 实验集表面位移预测散点图

实验集的预测范围为 [60.19, 148.42] mm, 预测均值为 94.43 mm。预测值随编号呈现出与训练集相似的变化趋势, 散点分布合理, 没有出现明显的系统性偏差或异常跳变, 表明模型在实验集上具有良好的泛化能力。预测结果的变化范围与训练集表面位移的范围 ([62.24, 193.11] mm) 基本一致, 进一步验证了训练集与实验集同分布假设的合理性。

七、问题四的建模与求解

7.1 问题分析

问题四提供了包含表面位移、降雨量、孔隙水压力、微震事件数、爆破点距离、单段最大药量等 6 维时序监测数据的训练集 (10000 条) 和实验集 (5000 条)。训练集时间跨度为 2023 年 5 月 1 日至 2023 年 7 月 10 日 (约 70 天), 表面位移范围为 [0.195, 654.690] mm, 包含了三阶段演变的完整过程。爆破事件仅 41 次 (占 0.4%), 为极稀疏偶发事件。实验集已给出阶段标签: 阶段 1 (缓慢, 2960 条)、阶段 2 (加速, 1530 条)、阶段 3 (快速, 510 条), 但不含表面位移数据。本问题的求解流程如图11所示。




图 11 问题四求解流程图

7.2 模型建立

7.2.1 训练集阶段识别

复用问题二的方法（Savitzky-Golay 滤波 + PELT 变点检测），对训练集的表面位移时序进行三阶段划分。识别结果为：缓慢阶段（编号 1–8450）、加速阶段（编号 8451–8950）、快速阶段（编号 8951–10000）。

7.2.2 特征工程

在原始 5 个特征变量的基础上，构建以下衍生特征以增强模型的表达能力。

爆破事件指示变量 $I_b(t)$ 用于标识爆破发生时刻，当爆破点距离 $D_b(t)$ 非空时取 1，否则取 0。爆破影响因子 $F_b(t)$ 借鉴萨道夫斯基公式的思想，定义为 $F_b(t) = Q_b(t)^{0.5}/D_b(t)$ （爆破时刻）或 0（非爆破时刻），综合反映爆破强度与距离的耦合效应。

降雨量滞后累积特征 $R_{cum,h}(t) = \sum_{i=0}^{6h/\Delta t} R(t - i \cdot \Delta t)$ 分别计算 1 小时、6 小时和 24 小时的累积降雨量，捕捉降雨对边坡位移的滞后效应。孔隙水压力变化率 $\Delta p_w(t) = p_w(t) - p_w(t - 6\Delta t)$ 反映 1 小时内孔隙水压力的变化趋势。微震事件 6 小时累积 $N_{s,cum}(t) = \sum_{i=0}^{36} N_s(t - i\Delta t)$ 反映岩体内部破裂的累积效应。阶段内归一化时间 $\tau_k(t) = (t - t_{k,start}) / (t_{k,end} - t_{k,start}) \in [0, 1]$ 作为时间趋势项，捕捉各阶段内位移随时间的演化规律。

经过特征工程，每个样本的特征维度从 5 个扩展到 14 个，为分阶段模型提供了丰富的输入信息。

7.2.3 分阶段 XGBoost 回归模型

对每个阶段 $k \in \{1, 2, 3\}$ ，独立训练 XGBoost 回归模型 [7]：

$$\hat{d}_{\text{surf}}^{(k)}(t) = F_k(\mathbf{x}(t)) = \sum_{m=1}^{M_k} f_{k,m}(\mathbf{x}(t)) \quad (23)$$

其中 $f_{k,m}$ 为第 m 棵回归树， M_k 为阶段 k 的树数量。XGBoost 的目标函数为：

$$\mathcal{L}^{(m)} = \sum_{i=1}^{N_k} l(d_{\text{surf},i}, \hat{d}_{\text{surf},i}^{(m-1)} + f_{k,m}(\mathbf{x}_i)) + \Omega(f_{k,m}) \quad (24)$$

其中损失函数 l 采用均方误差，正则化项 $\Omega(f) = \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2$ ， T 为叶节点数， w_j 为叶节点权重。

选择 XGBoost 作为预测模型的理由有三：其一，XGBoost 能够自动处理特征间的非线性交互效应，适合捕捉降雨、爆破、微震等因素对位移的复杂影响机制；其二，树模型天然支持稀疏数据，能够有效处理爆破事件的极稀疏特征（仅 0.4% 的时间点有爆破）；其三，XGBoost 内置 L1 和 L2 正则化，可有效防止过拟合。

分阶段建模的必要性在于：不同形变阶段中，各因素对位移的影响机制存在显著差异。在缓慢阶段，降雨和孔隙水压力是位移变化的主要驱动因素；而在快速阶段，坡体内部损伤累积成为主导因素，外部扰动的相对影响减弱。

7.2.4 阶段间连续性约束

为确保预测曲线在阶段转换点处连续，在阶段 2 和阶段 3 的预测中加入偏移校正：

$$\hat{d}_{\text{surf,corrected}}^{(k)}(t) = \hat{d}_{\text{surf}}^{(k)}(t) + \Delta_k \quad (25)$$

其中 $\Delta_k = \hat{d}_{\text{surf}}^{(k-1)}(t_k^*) - \hat{d}_{\text{surf}}^{(k)}(t_k^*)$ 为转换点处的预测值差。

7.3 模型求解

7.3.1 训练集拟合结果

分阶段 XGBoost 模型在训练集上的拟合结果如表7所示。

表 7 分阶段 XGBoost 模型训练集拟合结果

阶段	样本数	训练 R^2	训练 RMSE (mm)	特征数
Phase 1（缓慢）	8450	0.9999	0.154	14
Phase 2（加速）	500	0.9999	0.058	14
Phase 3（快速）	1050	0.9999	0.300	14

三个阶段的训练 R^2 均达到 0.9999 以上，RMSE 分别为 0.154 mm、0.058 mm 和 0.300 mm，说明分阶段 XGBoost 模型能够精确拟合各阶段的位移变化规律。快速阶段的 RMSE 相对较大（0.300 mm），这与该阶段位移变化幅度大、数据波动剧烈的特征一致。

7.3.2 实验集预测结果

利用实验集已给出的阶段标签，直接应用对应阶段的 XGBoost 模型进行预测。预测结果如图12所示。




图 12 实验集表面位移预测结果

预测曲线呈现出典型的三段式形变特征：缓慢阶段（2025 年 5 月 1 日至 5 月 22 日）位移缓慢线性增长，加速阶段（5 月 22 日至 6 月 1 日）位移增速明显加快，快速阶段（6 月 1 日之后）位移急剧攀升。阶段转换点处的预测曲线保持连续，没有出现不合理的跳变，说明连续性约束发挥了预期作用。

题目要求的 5 个时间点的表面位移预测值如表8所示。

表 8 实验集表面位移预测结果

时间点	表面位移预测值 (mm)
2025-05-09 12:00	5.622
2025-05-27 08:00	24.630
2025-06-01 12:00	74.577
2025-06-03 22:00	361.733
2025-06-04 01:40	376.115

预测结果的物理合理性分析如下：2025 年 5 月 9 日处于缓慢阶段早期，预测位移仅 5.622 mm，坡体变形微小。5 月 27 日已进入加速阶段，预测位移增至 24.630 mm，速度明显加快。6 月 1 日仍处于加速阶段后期，预测位移达 74.577 mm。6 月 3 日和 6 月 4 日处于快速阶段，预测位移分别为 361.733 mm 和 376.115 mm，仅相隔约 4 小时位移就增加了 14.4 mm，对应速度约 3.6 mm/h，符合快速形变阶段的特征。从缓慢阶段到快速阶段，位移量级从个位数增长到数百毫米，速度增长了约两个数量级，与三段式形变的理论预期完全一致。

八、问题五的建模与求解

8.1 问题分析

问题五提供了包含表面位移、降雨量、孔隙水压力、微震事件数、干湿入渗系数、爆破点距离、单段最大药量等 7 维时序监测数据（9450 条），时间跨度约 65 天，表面位移范围为 [0, 3557.771] mm，变化幅度极大，三阶段演化特征最为显著。爆破事件仅 47 次（占 0.5%），为极稀疏偶发事件。本问题包含两个子任务：最优变量组合选择（5.1）和预警机制构建（5.2）。求解流程如图13所示。




图 13 问题五求解流程图

8.2 问题 5.1：最优变量组合选择

8.2.1 变量组合评估框架

从 6 个候选变量（降雨量 X_1 、孔隙水压力 X_2 、微震事件数 X_3 、干湿入渗系数 X_4 、爆破点距离 X_5 、单段最大药量 X_6 ）中选取 5 个，共 $C_6^5 = 6$ 种组合。每种组合 $S_j = \{X_1, \dots, X_6\} \setminus \{X_j\}$ ($j = 1, 2, \dots, 6$) 采用相同的 XGBoost 模型框架，通过 TimeSeriesSplit 5 折交叉验证比较预测误差：

$$\text{Score}(S_j) = \frac{1}{K} \sum_{k=1}^K \text{RMSE}_k(S_j) \quad (26)$$

最优组合为 $S^* = \arg \min_{S_j} \text{Score}(S_j)$ 。

8.2.2 变量组合对比结果

6 种变量组合的交叉验证性能对比如图14和表9所示。




图 14 变量组合模型性能对比

表 9 6 种变量组合交叉验证性能对比

剔除变量	CV-RMSE (mm)	CV- R^2
降雨量	402.61	-7.74
孔隙水压力	357.27	-6.43
微震事件数	389.16	-5.84
干湿入渗系数	389.66	-6.85
爆破点距离	400.12	-7.63
单段最大药量	399.55	-7.56

剔除孔隙水压力后的组合 { 降雨量、微震事件数、干湿入渗系数、爆破点距离、单段最大药量 } 的 CV-RMSE 最小 (357.27 mm), 为最优变量组合。需要说明的是, CV- R^2 为负值是由于时间序列数据使用 TimeSeriesSplit 划分时, 训练集和验证集的分布存在差异 (不同阶段的位移量级差异巨大), 这是时间序列交叉验证的固有特征, 不影响组合间的相对排序。

最优模型在全量训练集上的拟合性能为 $R^2 = 0.9998$, RMSE = 14.13 mm, 说明选定的 5 个变量能够充分解释表面位移的变化规律。

8.2.3 最优组合的物理解释

孔隙水压力被剔除的原因在于其与其他变量 (尤其是降雨量和干湿入渗系数) 存在较强的共线性。从物理机制来看, 孔隙水压力的变化主要由降雨入渗驱动, 而干湿入渗系数直接描述了土体入渗能力的动态演变, 两者在信息层面存在较大的重叠。保留降雨量和干湿入渗系数已经能够充分捕捉水文因素对边坡位移的影响, 额外加入孔隙水压力反而引入了多重共线性, 降低了模型的泛化能力。

微震事件数与表面位移的相关性最强（ $r = 0.364$ ），反映了岩体内部破裂累积与宏观变形之间的因果关系。干湿入渗系数（ $r = 0.170$ ）反映了土体含水状态的动态变化，是连接气象因素与力学响应的桥梁。爆破点距离和单段最大药量虽然出现频率极低（0.5%），但在爆破发生时对位移的瞬时影响显著，保留这两个变量有助于模型准确预测爆破扰动下的位移响应。

8.3 问题 5.2：预警机制构建

8.3.1 阶段识别与速度统计

复用问题二的方法对附件 5 数据进行三阶段划分，识别结果为： $t_1 = 4350, t_2 = 8900$ 。各阶段的位移速度统计特征如表10所示。

表 10 各阶段位移速度统计特征

阶段	平均速度 (mm/h)	标准差 (mm/h)	速度范围 (mm/h)
Phase 1（缓慢）	1.017	0.857	[0, 4.2]
Phase 2（加速）	2.521	2.926	[0.3, 15.8]
Phase 3（快速）	9.919	0.442	[8.5, 11.2]

三个阶段的速度特征差异显著：缓慢阶段平均速度为 1.017 mm/h，加速阶段增至 2.521 mm/h（约为缓慢阶段的 2.5 倍），快速阶段达到 9.919 mm/h（约为缓慢阶段的 9.8 倍）。值得注意的是，快速阶段的速度标准差（0.442 mm/h）远小于加速阶段（2.926 mm/h），说明快速阶段的位移速度虽然很高但相对稳定，坡体已进入持续高速变形状态。

8.3.2 四级预警阈值设定

以表面位移速度为核心预警指标，基于各阶段的速度统计特征设定四级预警阈值。预警机制的设计遵循“分阶段、分等级、多指标”的原则，具体阈值如表11所示。

表 11 边坡滑坡四级预警阈值

预警等级	预警名称	速度阈值 (mm/h)	说明
I 级（蓝色）	注意	2.73	速度超出缓慢阶段正常波动范围
II 级（黄色）	警告	3.59	速度达到加速阶段起始水平
III 级（橙色）	紧急	8.37	速度达到快速阶段起始水平
IV 级（红色）	危险	10.80	速度超出快速阶段均值

各级阈值的计算依据如下。I 级阈值 $v_{th,I} = \bar{v}_1 + 2\sigma_{v,1} = 1.017 + 2 \times 0.857 = 2.731 \text{ mm/h}$, 对应正态分布的 97.7% 分位数, 当速度超出缓慢阶段正常波动范围时发出注意预警。II 级阈值 $v_{th,II} = \bar{v}_1 + 3\sigma_{v,1} = 1.017 + 3 \times 0.857 = 3.588 \text{ mm/h}$, 对应 99.7% 分位数, 当速度达到加速阶段起始水平时发出警告。III 级阈值 $v_{th,III} = \bar{v}_2 + 2\sigma_{v,2} \approx 8.373 \text{ mm/h}$, 当速度达到快速阶段起始水平时发出紧急预警。IV 级阈值 $v_{th,IV} = \bar{v}_3 + 2\sigma_{v,3} = 9.919 + 2 \times 0.442 = 10.804 \text{ mm/h}$, 当速度超出快速阶段均值时发出危险预警, 此时坡体已临近整体失稳。

预警机制的可视化结果如图15所示。



图 15 四级预警机制

位移速度时序曲线与四级预警阈值线的叠加展示了预警机制的运行效果。在缓慢阶段, 速度始终低于 I 级阈值, 系统处于安全状态。随着坡体进入加速阶段, 速度逐渐突破 I 级和 II 级阈值, 系统依次发出注意和警告预警。进入快速阶段后, 速度迅速突破 III 级和 IV 级阈值, 系统发出紧急和危险预警。

8.3.3 预警机制合理性分析

本文构建的四级预警机制具有以下合理性。从物理合理性来看, 阈值基于各阶段的统计特征确定, 反映了边坡从稳定到失稳的渐进过程, 与三段式形变的物理机制一致。从统计合理性来看, $\bar{v} + 2\sigma$ 对应正态分布的 97.7% 分位数, $\bar{v} + 3\sigma$ 对应 99.9% 分位数, 具有明确的统计意义, 能够有效控制误报率。从工程实用性来看, 四级预警体系与现行

地质灾害预警标准（蓝黄橙红四级）一致 [11, 13]，便于工程人员理解和执行。

灵敏度分析表明，当阈值倍数 k 从 1.5 增大到 3.0 时，I 级预警的首次触发编号从 2207 延后至 4367，预警点数从 2252 减少至 1578。 $k = 2.0$ 时的预警提前时间约为阶段转换前 25 个数据点（约 4.2 小时），在预警时效性和误报率之间取得了较好的平衡。

九、模型评价与推广

9.1 模型优点

（1）**系统性强**。本文构建了从传感器校正、形变阶段识别、多源数据预处理、分阶段位移预测到滑坡预警的完整技术体系，五个问题之间存在清晰的方法论递进关系。问题二的阶段识别方法为问题四和问题五的分阶段建模提供了统一框架，避免了各问题独立求解导致的方法不一致问题。

（2）**物理可解释性好**。各问题的模型选择均有明确的物理依据：问题一的多项式回归对应传感器的系统性偏差特征，问题二的三段式分段模型（线性 $\rightarrow$ 二次 $\rightarrow$ 指数）对应边坡蠕变理论的三个阶段，问题三的岭回归系数揭示了各监测变量对表面位移的贡献机制，问题五的预警阈值基于各阶段的速度统计特征确定。模型参数均具有明确的物理含义，便于工程人员理解和应用。

（3）**鲁棒性好**。灵敏度分析表明，问题一的多项式阶数在 $p \geq 2$ 后性能稳定（RMSE 变化 < 0.01 mm），问题二的变点检测结果对滤波窗口参数不敏感（窗口 21–101 范围内变点位置一致），问题五的预警阈值在 $k = 1.5 \sim 3.0$ 范围内均能有效识别阶段转换。10 折交叉验证和 TimeSeriesSplit 验证进一步证实了模型的泛化能力。

（4）**噪声处理方法科学**。针对边坡监测数据噪声强、异常跳变频繁的特点，本文采用了多层次的噪声处理策略：Savitzky-Golay 滤波保持趋势特征，小波阈值去噪分离信号与噪声，MAD 稳健 Z 分数法检测异常值，三条件联合判据区分噪声跳变与真实阶段转换。这些方法在理论上具有严格的数学依据，在实践中取得了良好的效果。

9.2 模型不足

（1）**线性假设的局限性**。问题三的岭回归模型假设各因素对表面位移的影响是线性的，但实际上降雨量与位移之间可能存在阈值效应（小雨量时影响微弱，超过某一阈值后影响急剧增大），线性模型无法捕捉这种非线性特征。5 折交叉验证 R^2 为 0.785，说明仍有约 21.5% 的变异未被解释。

（2）**时间序列特征利用不足**。问题四的 XGBoost 模型虽然通过滞后特征和累积特征部分捕捉了时间依赖性，但本质上仍是基于特征的静态模型，未能充分利用时间序列的自回归结构。LSTM 等深度学习模型可能在长期依赖关系的建模上具有优势 [9, 10]。

(3) **预警阈值的普适性有限**。问题五的预警阈值基于单一边坡的监测数据确定，不同地质条件、岩土类型的边坡可能需要不同的阈值设定。将预警机制推广到其他边坡时，需要根据当地的监测数据重新标定阈值参数。

9.3 模型推广

本文建立的技术体系具有较好的推广价值。传感器校正模型可推广到其他类型传感器的交叉校准场景，如 GPS 与全站仪的位移数据校正。三段式形变识别方法可应用于其他类型的渐进破坏过程监测，如大坝变形、地面沉降、隧道收敛等。分阶段预测模型的框架可推广到其他具有阶段性演化特征的工程问题。四级预警机制的设计思路可为其他地质灾害（如泥石流、崩塌）的预警系统提供参考。

在实际工程应用中，建议将本文的预警模型与实时监测系统集成，实现自动化的数据采集、处理、预测和预警。同时，随着监测数据的持续积累，可采用在线学习策略动态更新模型参数和预警阈值，提高预警系统的自适应能力。

参考文献

- [1] Saito M. Forecasting the time of occurrence of a slope failure[C]. Proceedings of the 6th International Conference on Soil Mechanics and Foundation Engineering, 1965: 537-541.
- [2] Fukuzono T. A new method for predicting the failure time of a slope[C]. Proceedings of the 4th International Conference and Field Workshop on Landslides, 1985: 145-150.
- [3] Killick R, Fearnhead P, Eckley I A. Optimal detection of changepoints with a linear computational cost[J]. Journal of the American Statistical Association, 2012, 107(500): 1590-1598.
- [4] Savitzky A, Golay M J E. Smoothing and differentiation of data by simplified least squares procedures[J]. Analytical Chemistry, 1964, 36(8): 1627-1639.
- [5] Donoho D L, Johnstone I M. Ideal spatial adaptation by wavelet shrinkage[J]. Biometrika, 1994, 81(3): 425-455.
- [6] Van Buuren S, Groothuis-Oudshoorn K. mice: Multivariate imputation by chained equations in R[J]. Journal of Statistical Software, 2011, 45(3): 1-67.

- [7] Chen T, Guestrin C. XGBoost: A scalable tree boosting system[C]. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2016: 785-794.
- [8] Lundberg S M, Lee S I. A unified approach to interpreting model predictions[C]. Advances in Neural Information Processing Systems, 2017: 4765-4774.
- [9] Ma J, Xia D, Wang Y, et al. A comprehensive comparison among metaheuristics (MHs) for geohazard modeling using machine learning: Insights from a case study of landslide displacement prediction[J]. Engineering Applications of Artificial Intelligence, 2022, 114: 105150.
- [10] Lian C, Zeng Z, Yao W, et al. Ensemble of extreme learning machine for landslide displacement prediction based on time series analysis[J]. Neural Computing and Applications, 2014, 24(1): 99-107.
- [11] Nandy S, Adhikari M, Ray A, et al. Edge-centric intelligent early warning system for residual soil stability prediction in slope[J]. IEEE Internet of Things Journal, 2024, 11(3): 3832-3839.
- [12] Zhao N, Wei J, Long Z, et al. An integrated method for tunnel health monitoring data analysis and early warning: Savitzky-Golay smoothing and wavelet transform denoising processing[J]. Sensors, 2023, 23(17): 7460.
- [13] Tohari A, Sugianti K, Hattori K. Monitoring and modelling of rainfall-induced landslide in volcanic soil slope[C]. Landslide Science and Practice, Springer, 2013: 503-510.
- [14] Stanke L, Kubicek J, Vilimek D, et al. Towards to optimal wavelet denoising scheme: A novel spatial and volumetric mapping of wavelet-based biomedical data smoothing[J]. Sensors, 2020, 20(18): 5301.
- [15] Dickow A, Feiertag G. Partially estimated polynomial MEMS sensor calibration[C]. Proceedings SENSOR 2015, AMA Service GmbH, 2015: 495-499.

附录 A 文件列表

表 12 提交文件清单

文件名	类型	说明
main.tex	LaTeX 源文件	论文主文件
paper/sections/*.tex	LaTeX 源文件	各章节内容
code/main.py	Python 脚本	主程序（串联所有子问题）
code/q1_calibration.py	Python 脚本	问题 1: 多项式回归校正
code/q2_phase_detection.py	Python 脚本	问题 2: 变点检测与分段建模
code/q3_preprocessing.py	Python 脚本	问题 3: 去噪、补齐、异常检测与关联分析
code/q4_prediction.py	Python 脚本	问题 4: 分阶段 XGBoost 预测
code/q5_variable_warning.py	Python 脚本	问题 5: 变量选择与预警机制
code/sensitivity_analysis.py	Python 脚本	灵敏度分析
code/utils.py	Python 脚本	公共工具函数
code/requirements.txt	依赖文件	Python 依赖库列表
figures/*.pdf	PDF 图片	各问题结果图表
figures/*.json	JSON 数据	各问题计算结果

附录 B 核心代码

2.1 问题 1: 多项式回归校正

```
1 import numpy as np
2 from sklearn.model_selection import KFold
3
4 def polynomial_calibration(A, B, degree=2, n_folds=10):
5     """多项式回归校正模型"""
6     # 拟合多项式
7     coeffs = np.polyfit(A, B, degree)
8     poly = np.poly1d(coeffs)
9     y_pred = poly(A)
10
11     # K折交叉验证
12     kf = KFold(n_splits=n_folds, shuffle=True, random_state=42)
13     metrics = {'rmse': [], 'mae': [], 'r2': []}
14     for train_idx, val_idx in kf.split(A):
15         c = np.polyfit(A[train_idx], B[train_idx], degree)
16         p = np.poly1d(c)
```



```

17     pred = p(A[val_idx])
18     residuals = B[val_idx] - pred
19     metrics['rmse'].append(np.sqrt(np.mean(residuals**2)))
20     metrics['mae'].append(np.mean(np.abs(residuals)))
21     ss_res = np.sum(residuals**2)
22     ss_tot = np.sum((B[val_idx] - np.mean(B[val_idx]))**2)
23     metrics['r2'].append(1 - ss_res / ss_tot)
24     return coeffs, metrics

```

Listing 1: 问题 1 核心代码

2.2 问题 2: PELT 变点检测

```

1 import ruptures
2 from scipy.signal import savgol_filter
3
4 def detect_phases(displacement, window=51, polyorder=3):
5     """三段式形变阶段识别"""
6     # Savitzky-Golay 滤波
7     d_smooth = savgol_filter(displacement, window, polyorder)
8
9     # 计算位移速率
10    w = 30 # 滑动窗口
11    velocity = np.zeros(len(d_smooth))
12    for i in range(w//2, len(d_smooth) - w//2):
13        velocity[i] = (d_smooth[i+w//2] - d_smooth[i-w//2]) / (w * 10/60)
14
15    # PELT变点检测
16    algo = ruptures.Pelt(model="rbf", min_size=500)
17    result = algo.fit_predict(velocity.reshape(-1,1),
18                             pen=np.log(len(velocity)))
19    return result, velocity, d_smooth

```

Listing 2: 问题 2 核心代码

2.3 问题 4: 分阶段 XGBoost 预测

```

1 import xgboost as xgb
2
3 def phased_xgboost_predict(train_data, test_data, phases):
4     """分阶段XGBoost回归预测"""
5     models = {}
6     for phase in [1, 2, 3]:
7         mask = phases == phase
8         X_train = train_data[mask].drop('displacement', axis=1)

```



```

9      y_train = train_data[mask][ 'displacement' ]
10     model = xgb.XGBRegressor(
11         n_estimators=300, max_depth=6,
12         learning_rate=0.1, subsample=0.8,
13         colsample_bytree=0.8, reg_lambda=1.0
14     )
15     model.fit(X_train, y_train)
16     models[phase] = model
17
18     # 实验集预测
19     predictions = []
20     for phase in test_data[ 'phase_label' ].unique():
21         mask = test_data[ 'phase_label' ] == phase
22         X_test = test_data[mask].drop( 'phase_label', axis=1)
23         pred = models[phase].predict(X_test)
24         predictions.append(pred)
25     return np.concatenate(predictions)

```

Listing 3: 问题 4 核心代码