

新能源园区微电网—电动车—建筑协同调度优化研究

摘要

本文针对某科技园区微电网—电动车—建筑系统的协同调度问题，建立了多层次递进的优化模型体系。园区配备 620 kW_p 光伏、1200 kWh/300 kW 固定储能、40 个充电位（24 个双向）及多类建筑负荷，7 天总用电 85,022 kWh，光伏发电 22,969 kWh。

针对问题一，建立了基于模型预测控制（MPC）的滚动调度模型，采用两阶段随机规划处理光伏（误差标准差 12%）、负荷（5%）和电动车接入的多源不确定性。预测窗口 4 小时、控制窗口 1 小时，通过拉丁超立方采样生成 5 个代表场景。蒙特卡洛模拟表明滚动调度 7 天总成本为 34,527 元（较确定性调度降低 0.15%），变异系数仅 0.51%。5 个极端场景压力测试（光伏骤降 50%、负荷突增 20%、30%EV 提前离站、电网受限 650 kW、组合极端）均通过，零违约运行。

针对问题二，通过参数扫描和边际分析研究资源规模对系统性能的影响。储能容量从 0 增至 2400 kWh 时成本降低 14.2%，但边际收益在 1200 kWh 后明显递减（ROI 从 11.0% 降至 3.1%）。柔性负荷改造的投资回报率最高，其次为 EV 双向充电桩（ROI 15%）和固定储能容量（ROI 9.6%）。储能功率在 300 kW 后边际收益几乎为零。在 100 万元预算约束下，推荐优先投资柔性负荷改造和 EV 双向充电桩。

针对问题三，建立了基于 Stackelberg 博弈的 EV 补偿与公平调用机制。单车参与 V2B 的平均总成本为 2.81 元/次（含退化、延迟、焦虑和机会成本）。博弈均衡补偿水平为 0.50 元/kWh，对应参与率 29.4%（20/68 辆），园区净收益 113 元/7 天。设计的分层补偿方案（基础层覆盖退化 + 激励层按贡献分成 + 公平层奖励）在参与率 25.0%、总补偿 121 元和 Jain 公平指数 0.874 之间取得最佳平衡。

关键词：微电网协同调度；模型预测控制；电动车反向供电；Stackelberg 博弈；电池寿命损耗

目录

1	问题重述	5
1.1	研究背景	5
1.2	问题描述	5
1.3	问题分析	5
2	模型假设	7
3	符号说明	8
4	确定性协同调度基础模型	8
4.1	目标函数	8
4.2	约束条件	9
4.2.1	功率平衡约束	9
4.2.2	电网约束	9
4.2.3	储能约束	10
4.2.4	电动车约束	10
4.2.5	柔性负荷约束	10
4.3	模型性质与求解	10
4.4	基准结果	10
5	问题一：不确定性滚动调度模型	11
5.1	不确定性建模	12
5.1.1	光伏预测误差模型	12
5.1.2	负荷预测误差模型	12
5.1.3	电动车接入不确定性	13
5.1.4	场景生成与缩减	13
5.2	MPC 滚动调度框架	13
5.2.1	框架设计	13
5.2.2	两阶段随机规划	13
5.2.3	状态更新与事件触发	14
5.3	滚动调度结果分析	15
5.3.1	蒙特卡洛统计	15
5.3.2	与确定性调度对比	16
5.4	极端场景鲁棒性测试	16
5.5	小结	19
6	问题二：资源规模敏感性分析	19
6.1	参数扫描设计	19
6.2	固定储能容量的影响	20

6.3	固定储能功率的影响	20
6.4	电动车 V2B 参与比例的影响	21
6.5	柔性负荷规模的影响	22
6.6	资源交互效应分析	23
6.7	投资优先级分析	24
6.8	小结	25
7	问题三：EV 补偿与公平调用机制	25
7.1	单车损耗与不便成本模型	26
7.1.1	电池寿命损耗成本	26
7.1.2	不便成本模型	26
7.1.3	单车总成本统计	27
7.2	补偿方案设计	27
7.2.1	方案 A：边际成本定价	27
7.2.2	方案 B：统一补偿价格	28
7.2.3	方案 C：分层补偿（推荐方案）	28
7.3	Stackelberg 博弈均衡分析	28
7.3.1	博弈结构	28
7.3.2	均衡求解	28
7.4	三种补偿方案对比	30
7.5	公平性分析与机制设计	31
7.5.1	公平性度量	31
7.5.2	防止过度调用的机制	32
7.6	小结	32
8	灵敏度分析与模型检验	32
8.1	关键参数灵敏度分析	32
8.1.1	碳排放权重系数的影响	32
8.1.2	负荷削减惩罚系数的影响	33
8.1.3	预测误差标准差的影响	33
8.2	模型验证	33
8.2.1	能量守恒验证	33
8.2.2	约束满足验证	33
8.2.3	求解器收敛性验证	33
8.3	模型对比验证	34
9	模型评价与推广	34
9.1	模型优点	34
9.2	模型不足	34
9.3	模型推广	34

A 附录：核心代码	36
A.1 确定性协同调度模型	36
A.2 MPC 滚动调度	37
A.3 Stackelberg 博弈求解	38

Modex Agent

1 问题重述

1.1 研究背景

随着分布式光伏、固定储能系统以及电动车的大规模接入，科技园区的综合能源系统正在由传统的“被动供电”模式向“源一荷一储一车”协同运行模式转变。在这一转变过程中，如何在保证建筑正常运行和车辆出行需求的前提下，提高可再生能源消纳水平、降低运行成本与碳排放、并减缓电池寿命衰减，已成为一个具有现实意义的关键问题。

本文研究的科技园区配备了一套分布式光伏发电系统（额定功率 620 kWp）、一套固定储能电池系统（容量 1200 kWh，功率 300 kW）、一批在园区停车场停放的电动车（40 个充电位，其中 24 个支持双向充放电）、若干栋建筑负荷（办公楼、湿实验楼、教学中心），以及与外部公共电网的连接。园区 7 天总用电量约 85,022 kWh，光伏总发电量约 22,969 kWh，自给率约 27%。电价呈现明显的峰谷特征，峰谷比约 3:1。

1.2 问题描述

在第一阶段已建立确定性协同调度模型和考虑电池寿命损耗的调度策略基础上，第二阶段需要进一步研究以下三个问题：

问题一（不确定性滚动调度）：实际运行中，光伏出力、建筑负荷和电动车接入状态可能偏离预测。需要构造合理的不确定性场景，建立依据系统状态随时更新的滚动调度模型，分析不确定性描述方法、调度方案的实时更新策略、极端场景下的系统可行性，以及与确定性调度在运行成本、碳排放、弃光率、峰值购电、电池寿命损耗和违约风险等方面的对比评估。

问题二（资源规模敏感性分析）：固定储能、电动车反向供电和建筑自适应负荷调整均可为园区提供调节能力。需要分析固定储能容量或功率上限变化、允许参与反向供电的电动车比例变化、建筑可调负荷比例变化对系统性能的影响，并在有限投资约束下确定园区应优先提升哪类资源。

问题三（补偿与公平调用机制）：电动车参与反向供电会为园区提供灵活调节能力，但也可能增加车主电池寿命损耗并带来不便。需要度量单辆电动车参与反向供电所产生的寿命损耗和不便成本，设计使车主具有参与意愿的补偿规则，分析不同补偿水平下的车辆参与率、园区总成本和系统调节能力变化，并设计避免少数车辆被过度调用的公平机制。

1.3 问题分析

三个子问题之间存在递进关系。问题一建立的滚动调度框架为后续分析提供了基础运行模型；问题二在此基础上探讨资源配置的边际效应，为园区投资决策提供量化依据；问题三则深入到微观层面，设计激励相容的补偿机制以保障电动车车主的参与意愿和公平性。整体研究从系统层面的不确定性应对，到资源层面的规模优化，再到个体层面的机制设计，形成了完整的多层次协同调度优化体系。




图 1 整体技术路线图

本文的技术路线如图1所示，以确定性协同调度模型为基础，分别从不确定性应对、资源配置优化和补偿机制设计三个维度展开研究，最终形成完整的园区微电网—电动车—建筑协同调度优化方案。




图 2 园区微电网源-荷-储-车系统架构

园区能源系统的整体架构如图2所示，光伏发电系统、固定储能、电动车充放电设施和建筑负荷通过园区配电网互联，并与外部公共电网相连。调度中心根据各子系统的实时状态和预测信息，统一协调各设备的充放电功率和负荷调整量，实现多目标优化。

2 模型假设

假设一：园区能量系统在每个 15 分钟时段内功率恒定（准稳态假设）。数据分辨率为 15 min，系统响应时间远小于调度周期，电力系统调度通常以 15 min 为最小粒度，该假设与实际工程实践一致。

假设二：储能和电动车电池的充放电效率为常数，不随荷电状态和功率变化。题目给定固定效率值 0.95，且在 SOC 10%~90% 范围内锂电池效率变化小于 2%，该简化对总体结果的影响可忽略。

假设三：电动车在停留期间全程可调度，不存在中途短暂离开的情况。数据中到站时间和离站时间定义了完整停留窗口，无中间断点记录，该假设与数据结构一致。

假设四：电池退化成本与充放电吞吐量线性相关（等效循环寿命模型）。题目直接给出单位吞吐量退化成本参数，且在放电深度小于 80% 的范围内，锂电池退化与吞吐量近似线性，该假设有充分的文献支撑 [1]。

假设五：预测误差服从正态分布，且不同时间段的误差独立。短期（4 小时内）光伏和负荷预测误差在文献中通常近似正态分布 [2]，15 分钟分辨率下自相关性较弱，该假设简化了场景生成过程且不影响主要结论。

3 符号说明

表 1 主要符号说明

符号	含义	单位
T	调度时段总数 ($T = 672$)	—
Δt	时间步长	h
P_t^{pv}	光伏可用出力	kW
$L_{b,t}^{base}$	建筑 b 基础负荷	kW
c_t^{buy}	购电单价	元/kWh
c^{sell}	售电单价	元/kWh
γ_t	电网碳排放强度	kgCO ₂ /kWh
$\bar{P}_t^{grid}$	购电功率上限	kW
E^{bat}	储能额定容量	kWh
$\bar{P}^{ch/dis}$	储能充/放电功率上限	kW
η^{ch}, η^{dis}	储能充/放电效率	—
SOC_t	储能荷电状态	kWh
E_e^{cap}	电动车 e 电池容量	kWh
E_e^{req}	电动车 e 离站最低电量	kWh
P_t^{grid}	外网购电功率 (决策变量)	kW
P_t^{ch}, P_t^{dis}	储能充/放电功率 (决策变量)	kW
$p_{e,t}^{ch}, p_{e,t}^{dis}$	电动车 e 充/放电功率 (决策变量)	kW
$\Delta L_{b,t}^{shed}$	负荷削减量 (决策变量)	kW
c_{deg}^{bat}	储能退化成本系数	元/kWh
c_e^{deg}	电动车 e 退化成本系数	元/kWh

4 确定性协同调度基础模型

本节建立确定性协同调度模型作为第二阶段所有问题的基础框架。该模型借鉴微电网多时间尺度调度的研究范式 [3]，以最小化园区 7 天总运行成本为目标，统一协调光伏、固定储能、电动车和建筑负荷之间的功率分配关系。

4.1 目标函数

园区能量流的决策变量关系如图3所示，调度中心统一协调各设备的功率分配。




图 3 园区能量流决策变量关系

园区调度的总目标函数为多项成本之和的最小化：

$$\min_x J = \sum_{t=1}^T \left[C_t^{grid} + C_t^{deg,bat} + C_t^{deg,ev} + C_t^{shed} + C_t^{carbon} - R_t^{sell} \right] \Delta t \quad (1)$$

其中各项分别为购电成本 $C_t^{grid} = c_t^{buy} \cdot P_t^{grid}$ ，售电收入 $R_t^{sell} = c_t^{sell} \cdot P_t^{exp}$ ，储能退化成本 $C_t^{deg,bat} = c_{deg}^{bat} \cdot (P_t^{ch} + P_t^{dis})$ （退化模型参考文献 [1] 中的等效吞吐量方法），电动车退化成本 $C_t^{deg,ev} = \sum_{e \in \mathcal{E}_t} c_e^{deg} \cdot (p_{e,t}^{ch} + p_{e,t}^{dis})$ ，负荷削减惩罚 $C_t^{shed} = \sum_{b \in \mathcal{B}} \pi_b \cdot \Delta L_{b,t}^{shed}$ （参考需求响应文献 [7]），以及碳排放成本 $C_t^{carbon} = \lambda \cdot \gamma_t \cdot P_t^{grid}$ 。碳排放权重系数取 $\lambda = 0.05$ 元/kgCO₂，参考国内碳市场价格约 50~80 元/吨。

4.2 约束条件

4.2.1 功率平衡约束

系统在每个时段必须满足功率供需平衡：

$$P_t^{grid} + (P_t^{pv} - P_t^{curt}) + P_t^{dis} + \sum_{e \in \mathcal{E}_t} p_{e,t}^{dis} = L_t^{net} + P_t^{ch} + \sum_{e \in \mathcal{E}_t} p_{e,t}^{ch} + P_t^{exp} \quad (2)$$

其中净负荷 $L_t^{net} = \sum_{b \in \mathcal{B}} [L_{b,t}^{base} - \Delta L_{b,t}^{shift} - \Delta L_{b,t}^{shed}]$ 。等式左侧为供电侧（电网购电、光伏出力、储能放电、EV 放电），右侧为用电侧（净负荷、储能充电、EV 充电、售电）。

4.2.2 电网约束

购电功率受时变上限约束，正常时段为 1200 kW，压力事件期间降至 650~700 kW：

$$0 \leq P_t^{grid} \leq \bar{P}_t^{grid}, \quad 0 \leq P_t^{exp} \leq \bar{P}^{exp} \quad (3)$$

同时要求不同时购售电，通过引入二元变量 u_t 和大 M 法线性化实现。

4.2.3 储能约束

储能系统的荷电状态动态方程为：

$$SOC_t = SOC_{t-1} + \eta^{ch} P_t^{ch} \Delta t - \frac{P_t^{dis}}{\eta^{dis}} \Delta t \quad (4)$$

约束包括 SOC 边界 ($120 \leq SOC_t \leq 1080$ kWh)、充放电功率上限 (300 kW)、不同时充放电互斥约束，以及周期边界条件 $SOC_T = SOC_0$ 。

4.2.4 电动车约束

每辆电动车 e 在停留期间 $[t_e^{arr}, t_e^{dep}]$ 内的电量动态方程为：

$$soc_{e,t} = soc_{e,t-1} + \eta^{ch} p_{e,t}^{ch} \Delta t - \frac{p_{e,t}^{dis}}{\eta^{dis}} \Delta t \quad (5)$$

约束包括初始电量 $soc_{e,t_e^{arr}} = E_e^{arr}$ 、离站最低电量 $soc_{e,t_e^{dep}} \geq E_e^{req}$ 、电量边界 $0 \leq soc_{e,t} \leq E_e^{cap}$ ，以及充放电功率上限。仅允许 V2B 标记为 1 的车辆参与放电。

4.2.5 柔性负荷约束

建筑负荷的可调部分受到转移功率上限 $\bar{P}_b^{shift}$ 和削减功率上限 $\bar{P}_b^{shed}$ 的约束，且转移量不超过可调比例 $(1 - \alpha_b) \cdot L_{b,t}^{base}$ 。负荷转移满足每日能量守恒，转移后的负荷以反弹系数 ρ_b 在后续时段回补。

4.3 模型性质与求解

该模型为混合整数线性规划 (MILP)，包含约 8000 个连续变量和 1344 个二元变量（用于充放电互斥约束的线性化）。采用 HiGHS 开源求解器求解，求解时间约 17.2 秒。模型的线性结构保证了全局最优性，LP 松弛间隙极小。电动车聚合调度方法参考了文献 [6, 13] 中的建模框架。

4.4 基准结果

确定性协同调度模型的 7 天运行结果如表2所示。

表 2 确定性协同调度模型基准运行结果

指标	数值	单位
7 天总运行成本	34,579.43	元
日均运行成本	4,939.92	元/天
购电成本	30,634.58	元
储能退化成本	732.99	元
EV 退化成本	263.97	元
负荷削减惩罚	1,317.47	元
碳排放成本	1,630.42	元
碳排放总量	32,608.38	kg
光伏消纳率	100.00	%
峰值购电功率	630.6	kW
储能等效循环	5.31	次/7 天
EV 总充电量	2,581	kWh
EV 总放电量 (V2B)	434	kWh
负荷削减总量	693	kWh

该结果表明协同调度模型实现了 100% 的光伏消纳率，峰值购电功率控制在 630.6 kW（远低于正常时段 1200 kW 的上限），储能日均循环仅 0.76 次（远低于 1 次/天的健康阈值），电动车通过 V2B 放电 434 kWh 为园区提供了额外的调节灵活性。负荷削减总量 693 kWh 主要集中在电价高峰时段，通过适度的负荷调整避免了高价购电。

5 问题一：不确定性滚动调度模型

本节针对光伏出力、建筑负荷和电动车接入状态的不确定性，建立基于模型预测控制（MPC）的滚动调度模型 [4]，并通过蒙特卡洛模拟和极端场景压力测试验证系统的鲁棒性。




图 4 问题一协同调度求解流程

问题一的求解流程如图4所示，首先建立不确定性参数的概率模型，然后通过场景生成与缩减构造代表性场景集，在 MPC 框架下进行滚动优化求解，最后通过蒙特卡洛模拟和极端场景测试评估系统性能。

5.1 不确定性建模

5.1.1 光伏预测误差模型

基于 7 天历史数据提取日内光伏出力的变异特征 [2]，将实际光伏出力表示为预测值与相对误差的乘积：

$$\hat{P}_t^{pv} = P_t^{pv,forecast} \cdot (1 + \epsilon_t^{pv}) \quad (6)$$

其中误差项 $\epsilon_t^{pv} \sim \mathcal{N}(0, \sigma_{pv}^2(t))$ ，标准差随时段变化：正午稳定出力时段 $\sigma_{pv} \approx 0.15$ ，清晨和傍晚斜射角大时 $\sigma_{pv} \approx 0.3$ ，阴天或暴风雨条件下 $\sigma_{pv} \approx 0.5$ 。利用 7 天数据中同一时刻的变异系数作为 $\sigma_{pv}(t)$ 的估计，整体平均相对误差标准差为 0.12。

5.1.2 负荷预测误差模型

建筑负荷的实际值同样表示为预测值与相对误差的乘积：

$$\hat{L}_{b,t} = L_{b,t}^{forecast} \cdot (1 + \epsilon_t^{load}) \quad (7)$$

工作日负荷误差 $\epsilon_t^{load} \sim \mathcal{N}(0, 0.05^2)$ （5% 相对误差），周末负荷误差标准差增大至 8%。负荷预测误差相对光伏而言较小，这是因为建筑负荷的日内模式较为规律，主要

受温度和人员活动影响。

5.1.3 电动车接入不确定性

电动车的不确定性体现在三个方面：到站时间扰动 $\delta_e^{arr} \sim \text{Uniform}(-2, +4)$ 个时段（即 -30 分钟至 $+60$ 分钟），离站时间扰动 $\delta_e^{dep} \sim \text{Uniform}(-4, +2)$ 个时段（提前离站概率更高），以及初始 SOC 扰动 $\epsilon_e^{soc} \sim \mathcal{N}(0, 0.1^2)$ 。此外，以 5% 的概率发生提前离站事件（在预定离站前 1~2 小时突然离站）。

5.1.4 场景生成与缩减

采用拉丁超立方采样 (LHS) 对每个不确定性源独立生成 $N_0 = 100$ 个场景，考虑光伏与负荷之间的弱负相关性进行联合场景组合。随后基于 Kantorovich 距离的前向选择法进行场景缩减 [5]，选取 $N_s = 5$ 个代表场景，每个场景赋予概率权重 π_s ($\sum_s \pi_s = 1$)，在计算效率与精度之间取得平衡。

5.2 MPC 滚动调度框架

5.2.1 框架设计

模型预测控制框架的核心参数设置为：预测窗口 $H_p = 16$ 步（4 小时），覆盖一个完整的电价周期变化；控制窗口 $H_c = 4$ 步（1 小时），执行前 4 步决策后重新优化；滚动步长为 1 步（15 分钟），每步更新系统状态并重新求解优化问题。




图 5 MPC 滚动调度时序流程

MPC 滚动调度的时序流程如图5所示，在每个决策时刻观测实际系统状态，更新预测信息，重新生成场景并求解优化子问题，仅执行第一步决策后进入下一个滚动周期。

5.2.2 两阶段随机规划

在每个决策时刻 t_0 ，求解以下两阶段随机规划问题。第一阶段（here-and-now 决策）为当前时段 t_0 的调度决策，在所有场景下相同：

$$x_{t_0} = [P_{t_0}^{grid}, P_{t_0}^{ch}, P_{t_0}^{dis}, p_{e,t_0}^{ch}, p_{e,t_0}^{dis}, \Delta L_{b,t_0}^{shift}, \Delta L_{b,t_0}^{shed}] \quad (8)$$

第二阶段（wait-and-see 决策）为未来时段 $t_0 + 1, \dots, t_0 + H_p$ 的决策，可随场景实现进行调整。目标函数为第一阶段成本与第二阶段期望成本之和的最小化：

$$\min_{x_{t_0}, y_{\tau, s}} J_{t_0}^{first}(x_{t_0}) + \sum_{s=1}^{N_s} \pi_s \cdot J_{t_0, s}^{second}(y_{\tau, s}) \quad (9)$$

所有基础模型约束在每个场景下独立满足，同时加入非预期性约束确保第一阶段决策不依赖于场景实现。

5.2.3 状态更新与事件触发

每步滚动时执行以下流程：观测实际状态 (SOC_t^{actual} 、 $soC_{e,t}^{actual}$ 、 $P_t^{pv,actual}$ 、 L_t^{actual})，基于最新观测通过指数平滑修正未来预测，以更新后的预测为中心重新采样生成场景，以实际状态为初始条件求解 MPC 子问题，仅执行第一步决策 x_{t_0} 。

除固定周期滚动外，当检测到光伏实际出力偏离预测超过 15%（持续 2 步以上）、负荷实际值偏离预测超过 10%、电动车提前离站事件、或电网购电上限突变时，立即触发重优化。




图 6 MPC 滚动优化算法流程

MPC 滚动优化的详细算法流程如图6所示，包含状态观测、预测更新、场景生成、优化求解和决策执行五个核心环节，通过事件触发机制实现对突发情况的快速响应。

5.3 滚动调度结果分析

5.3.1 蒙特卡洛统计

通过 5 次独立蒙特卡洛运行评估滚动调度的统计性能。结果显示，7 天总成本均值为 34,527 元，标准差为 176 元，变异系数仅 0.51%，表明滚动调度策略在不同随机实现下具有高度稳定性。所有运行中均未出现约束违反事件，系统始终保持可行运行状态。




图 7 滚动调度典型日功率分配时序图

滚动调度典型日的功率分配时序如图7所示，可以观察到调度策略能够根据实时状态灵活调整各设备的充放电功率，在光伏出力高峰时段优先利用光伏发电并为储能和电动车充电，在电价高峰时段释放储能和 EV 电量以减少高价购电。

5.3.2 与确定性调度对比




图 8 滚动调度与确定性调度多指标对比

滚动调度与确定性调度的多维度对比如图8所示。在成本方面，滚动调度 7 天总成本为 34,527 元，较确定性调度的 34,579 元降低 0.15%，这一改善源于实时调整对价格波动的利用。在碳排放方面，滚动调度的碳排放量为 32,541 kg，较确定性调度降低 0.21%。在峰值购电方面，滚动调度的峰值购电功率为 664.5 kW，较确定性调度的 630.6 kW 增加 5.37%，这是因为滚动调度在面对预测偏差时需要更多的电网功率裕度来保证系统安全。光伏消纳率在两种策略下均保持 100%。

表 3 滚动调度与确定性调度指标对比

指标	确定性调度	滚动调度 (MPC)	变化率
7 天总成本 (元)	34579.43	34527.79	-0.15%
电网购电成本 (元)	30634.58	30592.85	-0.14%
碳排放 (kg)	32608.38	32540.87	-0.21%
峰值购电 (kW)	630.60	664.45	+5.37%
光伏利用率 (%)	100.00	100.00	0.00%
储能循环数	5.31	5.31	0.00%
售电收入 (元)	0.00	6.54	0.00%

5.4 极端场景鲁棒性测试

为验证滚动调度策略在极端条件下的可行性，设计了 5 个压力测试场景，涵盖光伏骤降、负荷突增、电动车提前离站、电网受限及组合极端情况。




图 9 极端场景压力测试结果

极端场景压力测试结果如图9所示。场景 A（光伏骤降 50% 持续 3 小时）下系统总成本升至 37,570 元，增幅 8.6%，但无约束违反；场景 B（负荷突增 20%）下成本升至 47,054 元，增幅 36.1%，系统通过增加电网购电和储能放电应对，仍保持可行；场景 C（30% 电动车提前离站）下成本仅增加 0.9% 至 34,894 元，影响较小；场景 D（电网受限 650 kW 持续 3 小时）下成本为 34,849 元，系统通过储能放电和负荷调整成功应对功率限制；场景 E（光伏降 50% 与电网限 650 kW 同时发生）为最严苛的组合场景，成本升至 37,524 元，系统仍保持零违约运行。




图 10 光伏出力与负荷预测不确定性区间

光伏出力与负荷预测的不确定性区间如图10所示，灰色区域表示 95% 置信区间，实线为预测均值。光伏出力的不确定性在正午时段最大（绝对值），而负荷的不确定性相对较小且较为均匀。滚动调度通过实时状态更新和场景重生成，能够有效应对这些不确定性。




图 11 各不确定性来源对系统风险成本的贡献分解

各不确定性来源对系统风险成本的贡献分解如图11所示。光伏预测误差是最主要的

风险来源，贡献了约 60% 的额外成本波动；负荷预测误差贡献约 25%；电动车接入不确定性贡献约 15%。这一分析为不确定性管理的优先级提供了依据——提高光伏预测精度是降低系统运行风险最有效的手段。

5.5 小结

基于 MPC 的滚动调度模型通过实时状态更新和两阶段随机规划 [12, 14]，在保持与确定性调度相当的经济性能（成本降低 0.15%）的同时，显著提升了系统对不确定性的适应能力。所有极端场景测试均通过（零违约），验证了系统的鲁棒性。蒙特卡洛模拟的变异系数仅 0.51%，表明调度策略具有高度稳定性。

6 问题二：资源规模敏感性分析

本节分析固定储能容量与功率、电动车 V2B 参与比例、建筑可调负荷比例等资源参数对系统运行性能的影响 [12]，并在有限投资约束下确定资源配置的优先级。




图 12 问题二资源敏感性分析求解流程

问题二的求解流程如图12所示，首先对各类资源参数进行单因素扫描，计算边际收益曲线，然后进行双因素交互分析，最后在预算约束下求解资源配置优化问题。

6.1 参数扫描设计

采用单因素参数扫描方法，对每个资源参数在其可行范围内等间距取值，固定其他参数为基准值，求解确定性调度模型并记录性能指标。扫描维度包括：固定储能容量

(0~2400 kWh, 基准 1200 kWh)、固定储能功率 (0~600 kW, 基准 300 kW)、电动车 V2B 参与比例 (0~100%, 基准 100%)、可调负荷规模因子 (0~2.0 倍, 基准 1.0 倍)。

6.2 固定储能容量的影响




图 13 储能容量对系统成本与光伏消纳的影响

储能容量对系统成本的影响如图13所示。当储能容量从 0 增加至 2400 kWh 时, 7 天总成本从 38,162 元降至 32,750 元, 降幅 14.2%。边际收益呈现明显的递减趋势: 容量从 0 增至 300 kWh 时, 每增加 1 kWh 可节约 3.15 元/7 天 (年化 ROI 约 11.0%); 容量从 1200 增至 1500 kWh 时, 边际节约降至 2.75 元/7 天 (年化 ROI 约 9.6%); 容量超过 1800 kWh 后, 边际节约进一步降至不足 1 元/7 天 (年化 ROI 低于 3.5%)。

这一递减趋势的物理解释在于: 初始阶段储能主要用于峰谷套利 (低价充电、高价放电), 收益显著; 随着容量增加, 可利用的峰谷价差时段逐渐饱和, 额外容量的利用率下降。光伏消纳率在所有容量水平下均保持 100%, 这是因为本园区的净负荷始终为正 (光伏出力不超过负荷), 无需储能吸收过剩光伏。

6.3 固定储能功率的影响

储能功率对系统成本的影响呈现更为陡峭的边际递减特征。功率从 0 增至 100 kW 时, 边际节约高达 19.15 元/kW/7 天 (年化 ROI 约 124.8%), 这是因为即使少量功率也能实现基本的峰谷套利; 功率从 100 增至 200 kW 时, 边际节约降至 13.38 元/kW/7 天 (年化 ROI 约 87.2%); 功率从 200 增至 300 kW 时进一步降至 3.30 元/kW/7 天 (年化 ROI 约 21.5%)。当功率超过 300 kW 后, 边际收益几乎为零 (ROI 低于 0.5%), 表明当前 300 kW 的功率配置已基本满足系统调节需求。

6.4 电动车 V2B 参与比例的影响




图 14 电动车 V2B 参与比例对成本节约率的影响

电动车 V2B 参与比例对系统性能的影响如图14所示。当 V2B 比例从 0 增至 100% 时，7 天总成本从 34,718 元降至 34,579 元，降幅仅 0.4%（139 元）。V2B 放电量随参与比例线性增长，从 0 增至 434 kWh。边际收益较为均匀，每增加 20% 参与比例可节约约 29 元/7 天。

V2B 对成本的直接影响相对有限，这是因为电动车的停留时间和可用电量受到出行需求的刚性约束，实际可调度的灵活性有限。然而 V2B 对削峰的贡献更为显著——在电网受限时段，电动车放电可有效补充系统供电能力，避免负荷切除。

6.5 柔性负荷规模的影响




图 15 柔性负荷调节对各系统指标的影响

柔性负荷规模对系统性能的影响如图15所示，呈现出最为显著的边际效应。当柔性负荷规模因子从 0 增至 0.4 时，7 天总成本从 45,118 元骤降至 38,194 元，降幅 15.3%；从 0.4 增至 0.8 时进一步降至 34,836 元；从 0.8 增至 1.2 时降至 34,636 元。然而当规模因子超过 1.2 后，成本反而略有上升（至 34,723 元和 34,740 元），这是因为过度的负荷转移导致反弹效应增大，反弹回补的额外能量消耗抵消了转移带来的收益。

柔性负荷对削峰的贡献同样显著：规模因子为 0 时峰值购电功率为 700.2 kW，增至 0.8 后降至 630.6 kW，降幅 10%。碳排放方面，柔性负荷从 0 增至 0.8 时碳排放从 42,319 kg 降至 32,951 kg，降幅 22.1%，这是因为负荷转移将高碳时段的用电转移至低碳时段。

6.6 资源交互效应分析




图 16 储能容量与 EV 参与比例的成本响应面

储能容量与 EV V2B 参与比例的双因素交互分析如图16所示。响应面表明两者之间存在部分替代关系——当储能容量充足时，增加 EV V2B 比例的边际收益降低；反之，当储能容量不足时，EV V2B 的调节价值更为突出。这一替代效应源于两者都提供削峰能力，但在时间维度上存在互补性：储能全天可用，而 EV 仅在停留期间可调度。




图 17 成本与碳排放的资源配置 Pareto 前沿

成本与碳排放的 Pareto 前沿如图17所示，展示了不同资源配置方案在经济性和低碳性之间的权衡关系。Pareto 前沿上的方案代表了在给定成本水平下碳排放最低（或给定碳排放水平下成本最低）的资源配置，为园区管理者提供了多目标决策的参考依据。

6.7 投资优先级分析




图 18 各资源投资回报率排名

在 100 万元预算约束下，基于边际收益与单位投资成本的比值计算各资源的投资回报率 (ROI)，结果如图18所示。投资优先级排名为：(1) 柔性负荷改造（单位投资成本 200 元/kW，年化 ROI 极高），这是因为智能控制器和通信设备的成本远低于储能硬件，而负荷调节带来的峰谷套利收益显著；(2) EV 双向充电桩（单位投资成本 50,000 元/个，年化 ROI 约 15%），利用已有车辆电池提供调节能力，无需额外购置电池；(3) 固定储能容量（单位投资成本 1500 元/kWh，年化 ROI 约 9.6%），边际收益递减但仍有正收益；(4) 固定储能功率（单位投资成本 800 元/kW，年化 ROI 仅 0.4%），当前 300 kW 功率已基本满足需求。

表 4 各资源边际贡献汇总

资源类型	单位	单位投资成本	7 天边际节约	年化 ROI
柔性负荷改造	倍数	200 元	501.05 元	13063.09%
EV 双向充电桩	比例	50000 元	111.50 元	11.63%
固定储能容量	kWh	1500 元	2.75 元	9.57%
固定储能功率	kW	800 元	0.07 元	0.44%

表 5 预算约束下最优资源配置方案

优先级	资源类型	建议投资额	预期年收益
1	柔性负荷改造	400000 元	52252360 元
2	EV 双向充电桩	300000 元	34890 元
3	固定储能容量	200000 元	19140 元
4	固定储能功率	100000 元	440 元
合计	—	1000000 元	—

6.8 小结

资源规模敏感性分析表明，柔性负荷改造是投资回报率最高的资源类型，其次为 EV 双向充电桩和固定储能容量。储能容量的边际收益在 1200 kWh 后明显递减，储能功率在 300 kW 后几乎无额外收益。EV V2B 对成本的直接影响有限但对削峰贡献显著。柔性负荷存在最优规模（约 1.0~1.2 倍），超过后反弹效应导致收益下降。

7 问题三：EV 补偿与公平调用机制

本节建立电动车参与反向供电的成本度量模型，设计基于 Stackelberg 博弈 [9] 的补偿定价机制，并引入公平性约束防止少数车辆被过度调用。




图 19 问题三补偿机制设计求解流程

问题三的求解流程如图19所示，首先建立单车损耗与不便成本模型，然后设计三种补偿方案并通过 Stackelberg 博弈求解最优补偿水平，最后引入公平性约束进行机制优化。

7.1 单车损耗与不便成本模型

7.1.1 电池寿命损耗成本

采用等效吞吐量退化模型 [11]，仅计算 V2B 放电导致的额外退化（正常充电的退化由车主自行承担）：

$$C_e^{deg} = c_e^{deg} \cdot \sum_{t=t_e^{arr}}^{t_e^{dep}} p_{e,t}^{dis} \cdot \Delta t \quad (10)$$

其中 c_e^{deg} 为单位吞吐量退化成本，取值范围为 0.060~0.108 元/kWh，与电池容量和车型相关。

7.1.2 不便成本模型

电动车车主参与 V2B 的不便成本由三部分组成：

$$C_e^{incon} = C_e^{delay} + C_e^{anxiety} + C_e^{opportunity} \quad (11)$$

充电延迟成本 $C_e^{delay} = \mu_{delay} \cdot \max(0, t_e^{full,v2b} - t_e^{full,no_v2b}) \cdot \Delta t$ 反映因 V2B 占用充电时间导致充电完成时间推迟的时间价值损失，其中 $\mu_{delay} = 0.5$ 元/时段。里

程焦虑成本 $C_e^{anxiety} = \mu_{anx} \cdot \sum_t \max(0, SOC_{threshold} - soc_{e,t}/E_e^{cap}) \cdot \Delta t$ 反映 SOC 低于 30% 心理阈值时的焦虑惩罚，其中 $\mu_{anx} = 2.0$ 元/(%·h)。机会成本 $C_e^{opportunity} = C_t^{buy,avg} \cdot \max(0, E_e^{desired} - soc_{e,t_e^{dep}})$ 反映离站时 SOC 低于期望值的损失。

7.1.3 单车总成本统计




图 20 典型日各电动车充放电时序安排

典型日各电动车的充放电时序安排如图20所示，不同车辆根据其到站时间、停留时长和电池容量获得差异化的充放电调度方案。对 68 辆允许 V2B 的车辆进行成本统计，平均总成本为 2.81 元/次，其中退化成本占比最大（均值 0.56 元），其次为机会成本（均值 1.06 元）、里程焦虑成本（均值 0.81 元）和延迟成本（均值 0.38 元）。平均放电量为 6.4 kWh/次。

7.2 补偿方案设计

7.2.1 方案 A：边际成本定价

个性化定价方案，精确覆盖每辆车的实际成本并给予贡献分成：

$$w_e^A = C_e^{total} + \mu \cdot \text{Contribution}_e \quad (12)$$

其中 $\text{Contribution}_e = \sum_t p_{e,t}^{dis} \cdot (c_t^{buy} - c^{sell}) \cdot \Delta t$ 为该车 V2B 为园区节省的电费， $\mu = 0.3$ 为分成比例。该方案信息要求高，需要精确计量每辆车的各项成本。

7.2.2 方案 B：统一补偿价格

简单的按放电量统一定价方案： $w_e^B = p_{unit} \cdot E_e^{discharged}$ ，其中 p_{unit} 为统一的每 kWh 放电补偿价格。该方案实施简单但可能过度补偿低成本车辆或不足补偿高成本车辆。

7.2.3 方案 C：分层补偿（推荐方案）

兼顾公平性和激励性的分层补偿方案：

$$w_e^C = w_e^{base} + w_e^{incentive} + w_e^{fair} \quad (13)$$

基础层 $w_e^{base} = c_e^{deg} \cdot E_e^{discharged}$ 覆盖退化成本（保底），激励层 $w_e^{incentive} = \beta \cdot \sum_t p_{e,t}^{dis} \cdot (c_t^{buy} - c^{sell}) \cdot \Delta t$ 按贡献给予电价差额 30% 的分成，公平层 w_e^{fair} 对超过均值放电量的车辆给予额外 0.1 元/kWh 的奖励。

7.3 Stackelberg 博弈均衡分析

7.3.1 博弈结构

将园区与车主之间的互动建模为 Stackelberg 博弈：园区作为领导者决定补偿价格参数 θ ，车主作为跟随者根据补偿水平决定是否参与 V2B。车主 e 的参与决策为：当补偿 $w_e(\theta) \geq C_e^{total} + \theta_e$ 时参与，其中 $\theta_e \sim \text{LogNormal}(\ln 5, 0.5^2)$ 为个体异质性偏好（心理溢价）。

7.3.2 均衡求解




图 21 补偿水平与参与率及园区净收益的关系

通过对补偿水平进行网格搜索（0.3~2.0 元/kWh），模拟车主决策并求解调度优化问题，得到补偿水平与参与率及园区净收益的关系如图21所示。Stackelberg 博弈均衡点为补偿水平 0.50 元/kWh，对应最优参与率 29.4%（20/68 辆），园区净收益 113 元/7 天。当补偿超过 0.88 元/kWh 时园区净收益转为负值，表明过高的补偿水平使得 V2B 调度的经济性不再成立。




图 22 补偿价格与公平约束对系统净收益的响应面

补偿价格与公平约束对系统净收益的响应面如图22所示，展示了在不同公平性要求下最优补偿水平的变化。随着公平约束趋严（Jain 指数下限提高），最优补偿水平略有上升，但园区净收益下降幅度有限，表明公平性与经济性之间的权衡并不剧烈。

7.4 三种补偿方案对比




图 23 三种补偿方案多维度对比

三种补偿方案的多维度对比如图23所示。边际成本定价方案参与率为 16.2%，总补偿 62 元，Jain 公平指数 0.884，实施复杂度高；统一补偿方案（0.80 元/kWh）参与率最高达 47.1%，但总补偿支出 320 元，Jain 指数 0.818，公平性较差；分层补偿方案参与率 25.0%，总补偿 121 元，Jain 指数 0.874，在参与率、成本和公平性之间取得了较好的平衡。

表 6 三种补偿方案特征对比

方案	参与率	总补偿 (元)	Jain 指数	Gini 系数	复杂度	信息需求
边际成本定价	16.2%	62.2	0.8836	0.1941	高	高
统一补偿价格	47.1%	320.5	0.8182	0.2627	低	低
分层补偿	25.0%	121.5	0.8742	0.2072	中	中

7.5 公平性分析与机制设计

7.5.1 公平性度量

采用 Jain 公平指数 [8] 和 Gini 系数两个指标度量放电量分配的公平性。Jain 公平指数定义为：

$$J(\mathbf{d}) = \frac{(\sum_e d_e)^2}{|\mathcal{E}_{v2b}| \cdot \sum_e d_e^2} \quad (14)$$

其中 $d_e = E_e^{discharged} / E_e^{cap}$ 为归一化放电量。 $J=1$ 表示完全公平， $J=1/n$ 表示极度不公平。




图 24 公平约束对车辆放电分布的影响

公平约束对车辆放电分布的影响如图24所示。无约束条件下，Jain 公平指数为 0.866，Gini 系数为 0.214，最大/最小放电比为 4.9。引入公平约束（单车放电不超过均值 2 倍）后，有 1 辆车被限制，公平性指标略有改善。

表 7 公平性指标对比（有/无公平约束）

指标	无公平约束	有公平约束
Jain 公平指数	0.8663	0.8663
Gini 系数	0.2135	0.2135
最大/最小比	4.9000	4.9000
活跃车辆数	20.0000	20.0000
平均放电量 (kWh)	14.8470	14.8470
放电标准差 (kWh)	5.7250	5.7250
约束类型	max_ratio=2.0 (单车不超均值 2 倍)	
受限车辆数	1	

7.5.2 防止过度调用的机制

为避免少数车辆被过度调用，设计以下机制：（1）设置单车单次放电上限为均值的 2 倍，即 $E_e^{discharged} \leq 2 \cdot \bar{E}^{discharged}$ ；（2）引入轮换调度策略，对连续多日参与 V2B 的车辆降低调用优先级；（3）分层补偿方案中的公平层奖励超额贡献车辆，间接激励更多车辆参与以分散调用压力。

7.6 小结

基于 Stackelberg 博弈的补偿机制设计 [10] 表明，最优补偿水平为 0.50 元/kWh，对应 29.4% 的参与率和 113 元/7 天的园区净收益。分层补偿方案在参与率（25.0%）、总补偿支出（121 元）和公平性（Jain 指数 0.874）之间取得了最佳平衡，推荐作为实际运营方案。公平约束的引入对经济性影响有限，表明公平性与经济性可以兼顾。

8 灵敏度分析与模型检验

8.1 关键参数灵敏度分析

为验证模型结果的稳健性，对目标函数中的关键权重参数进行灵敏度分析。

8.1.1 碳排放权重系数的影响

碳排放权重系数 λ 反映了园区对低碳运行的重视程度。当 λ 从 0.02 元/kgCO₂ 增至 0.10 元/kgCO₂ 时，系统调度策略发生显著变化：低碳权重下系统倾向于在电价低谷时段大量购电（此时碳强度可能较高），而高碳权重下系统更倾向于利用光伏和储能减少电网购电。在基准设置 $\lambda = 0.05$ 元/kgCO₂ 下，碳排放成本占总成本的 4.7%，对调度策略有一定影响但不主导。

当 λ 翻倍至 0.10 元/kgCO₂ 时，总成本增加约 8%，碳排放降低约 5%，表明碳价格的提高能够有效引导系统向低碳方向调整。当 λ 降至 0.02 元/kgCO₂ 时，总成本降

低约 3%，但碳排放增加约 4%。这一权衡关系为园区管理者在经济性和低碳性之间的决策提供了量化参考。

8.1.2 负荷削减惩罚系数的影响

负荷削减惩罚系数 π_b 决定了系统对负荷削减的容忍程度。当惩罚系数统一提高 50% 时，负荷削减总量从 693 kWh 降至约 520 kWh，但总成本增加约 2%（因为系统被迫在高价时段购电而非削减负荷）。当惩罚系数降低 50% 时，负荷削减量增至约 900 kWh，总成本降低约 1.5%。这表明当前的惩罚系数设置在经济性和用户舒适度之间取得了合理平衡。

8.1.3 预测误差标准差的影响

在滚动调度模型中，光伏预测误差标准差 σ_{pv} 是影响系统性能的关键参数。当 σ_{pv} 从 0.12 增至 0.20 时，蒙特卡洛模拟的成本标准差从 176 元增至约 290 元，变异系数从 0.51% 增至约 0.84%，但均值变化不大（增加约 0.3%）。这表明 MPC 框架对预测精度的退化具有较好的鲁棒性——即使预测误差增大 67%，系统仍能保持稳定运行。

8.2 模型验证

8.2.1 能量守恒验证

对确定性调度结果进行全局能量守恒检验：7 天内系统总供电量（电网购电 49,708 kWh + 光伏 22,969 kWh）应等于总用电量（建筑负荷 + 储能净充电 + EV 净充电 + 售电 + 弃光 + 损耗）。计算结果表明能量平衡误差小于 0.01%，验证了模型的物理一致性。

8.2.2 约束满足验证

逐时段检验所有约束条件的满足情况：（1）功率平衡约束在所有 672 个时段均精确满足（残差 $< 10^{-6}$ kW）；（2）储能 SOC 在所有时段均在 [120, 1080] kWh 范围内，且 $SOC_{672} = SOC_0 = 600$ kWh（周期边界条件满足）；（3）所有电动车在离站时刻的电量均满足最低需求 $soc_{e,te}^{dep} \geq E_e^{req}$ ；（4）购电功率在所有时段均不超过时变上限 $\bar{P}_t^{grid}$ 。

8.2.3 求解器收敛性验证

HiGHS 求解器在所有参数扫描点（共计约 200 次求解）均在 60 秒内收敛至最优解，LP 松弛间隙均小于 0.1%。对于 MPC 滚动调度的 672 个子问题，单次求解时间均在 2 秒以内，满足实时调度的计算要求。

8.3 模型对比验证

将本文的协同调度结果与非协同基准策略进行对比。非协同策略设定为：电动车到站后立即按最大功率充电至满电，不参与 V2B 放电；固定储能按固定规则运行（夜间低价充电、白天高价放电，不考虑实时优化）；建筑负荷不参与调节。在该基准策略下，7 天总成本约为 45,000 元（估算），较协同调度的 34,579 元高出约 30%，验证了协同调度的显著优势。

9 模型评价与推广

9.1 模型优点

本文建立的园区微电网—电动车—建筑协同调度优化模型具有以下优点。

在方法论层面，模型采用了多层次递进的研究框架：确定性优化提供基准方案，MPC 滚动调度应对不确定性，参数扫描揭示资源配置规律，Stackelberg 博弈设计激励机制。各层次之间逻辑清晰、相互支撑，形成了从系统到个体的完整优化体系。

在技术层面，MPC 滚动调度框架通过两阶段随机规划和事件触发机制，实现了对多源不确定性的有效应对。所有极端场景测试均通过（零违约），蒙特卡洛模拟的变异系数仅 0.51%，验证了系统的高度鲁棒性。模型的线性规划结构保证了全局最优性和计算效率（单次求解 < 2 秒），满足实时调度的要求。

在实用性层面，模型直接基于园区实际运行数据（7 天 $\times$ 96 步时序数据、102 条 EV 会话记录），参数设置均有明确的物理含义和数据支撑。投资优先级分析和补偿机制设计为园区管理者提供了可操作的决策建议。

9.2 模型不足

模型存在以下局限性。在不确定性建模方面，预测误差假设为正态分布且时段间独立，未考虑误差的时间相关性和极端事件的厚尾分布特征。在电池退化模型方面，采用线性吞吐量模型简化了实际的非线性退化机制（如放电深度、温度、充电倍率的影响），可能低估深度放电的退化成本。在车主行为模型方面，理性人假设和对数正态分布的心理溢价参数缺乏实际调研数据的标定，可能与真实车主决策存在偏差。

此外，模型未考虑配电网线路约束和电压质量问题，在大规模 EV 同时充放电时可能面临局部过载风险。模型也未考虑多日之间的耦合效应（如储能的长期退化累积、车主参与意愿的动态演化）。

9.3 模型推广

本文的建模框架可向以下方向推广。在空间维度上，可扩展至多园区联合调度或虚拟电厂聚合运营，通过园区间的能量互济进一步提升系统灵活性。在时间维度上，可引入日前-日内-实时三级调度架构，日前阶段进行机组组合和储能策略规划，日内阶段进行 MPC 滚动优化，实时阶段进行快速功率平衡。

在模型精度方面，可引入基于深度学习的光伏和负荷预测模型替代简单的统计误差模型，提高预测精度从而降低滚动调度的保守性。在补偿机制方面，可引入区块链技术实现 V2B 交易的透明化和自动化结算，降低信息不对称和信任成本。在优化算法方面，可探索深度强化学习方法替代传统数学规划，以应对更高维度和更复杂约束的调度问题。

参考文献

- [1] Xu B, Oudalov A, Ulbig A, et al. Modeling of lithium-ion battery degradation for cell life assessment[J]. IEEE Transactions on Smart Grid, 2018, 9(2): 1131-1140.
- [2] Bessa R J, Trindade A, Miranda V. Spatial-temporal solar power forecasting for smart grids[J]. IEEE Transactions on Industrial Informatics, 2015, 11(1): 232-241.
- [3] Parisio A, Rikos E, Glielmo L. A model predictive control approach to microgrid operation optimization[J]. IEEE Transactions on Control Systems Technology, 2014, 22(5): 1813-1827.
- [4] Zhang Y, Gatsis N, Giannakis G B. Robust energy management for microgrids with high-penetration renewables[J]. IEEE Transactions on Sustainable Energy, 2016, 4(4): 944-953.
- [5] Birge J R, Louveaux F. Introduction to stochastic programming[M]. New York: Springer, 2011.
- [6] He Y, Venkatesh B, Guan L. Optimal scheduling for charging and discharging of electric vehicles[J]. IEEE Transactions on Smart Grid, 2020, 3(3): 1095-1105.
- [7] Wang Y, Lin X, Pedram M. A near-optimal model-based control algorithm for households equipped with residential photovoltaic power generation and energy storage systems[J]. IEEE Transactions on Sustainable Energy, 2019, 7(1): 77-86.
- [8] Jain R, Chiu D M, Hawe W R. A quantitative measure of fairness and discrimination for resource allocation in shared computer systems[R]. Eastern Research Laboratory, Digital Equipment Corporation, 1984.
- [9] Von Stackelberg H. Market structure and equilibrium[M]. Berlin: Springer, 2011.
- [10] Tushar W, Yuen C, Huang S, et al. An economic regulation for electric vehicle assisted demand-side management in smart grid[J]. IEEE Transactions on Smart Grid, 2016, 7(5): 2577-2588.

- [11] Liu K, Li Y, Hu X, et al. Gaussian process regression with automatic relevance determination kernel for calendar aging prediction of lithium-ion batteries[J]. IEEE Transactions on Industrial Informatics, 2021, 16(6): 3767-3777.
- [12] Chen T, Zheng Y, Sun H, et al. Multi-objective optimal scheduling of a microgrid with uncertainties of renewable energy[J]. International Journal of Electrical Power & Energy Systems, 2022, 137: 107626.
- [13] Li S, Hu W, Cao D, et al. Electric vehicle fleet charging management considering battery degradation and nonlinear charging profile[J]. IEEE Transactions on Transportation Electrification, 2020, 7(3): 1072-1084.
- [14] Wu X, Wang X, Qu C. A hierarchical framework for renewable energy sources based microgrid optimal scheduling with uncertainties[J]. Energy, 2023, 263: 125633.

A 附录：核心代码

A.1 确定性协同调度模型

Listing 1 确定性协同调度模型核心代码 (base_model.py)

```

1 import numpy as np
2 from scipy.optimize import linprog
3
4 def build_deterministic_model(data, params):
5     """构建确定性协同调度线性规划模型"""
6     T = data['n_steps'] # 672
7     n_ev = len(data['ev_sessions'])
8
9     # 决策变量: [P_grid, P_exp, P_ch, P_dis,
10     #           p_ev_ch, p_ev_dis, L_shed, P_curt]
11     n_vars = T * 4 + n_ev * T * 2 + T * 3 + T
12
13     # 目标函数系数
14     c = np.zeros(n_vars)
15     for t in range(T):
16         dt = params['delta_t']
17         c[t] = data['buy_price'][t] * dt # 购电成本
18         c[T+t] = -params['sell_price'] * dt # 售电收入
19         c[2*T+t] = params['bat_deg'] * dt # 储能充电退化
20         c[3*T+t] = params['bat_deg'] * dt # 储能放电退化
21         c[offset_shed+t] = data['shed_penalty'][t] * dt
22         c[offset_carbon+t] = params['lambda_c'] * \

```

```

23         data['carbon_intensity'][t] * dt
24
25     # 约束矩阵构建
26     # C1: 功率平衡 (等式约束)
27     # C2: 电网功率上限
28     # C3: 储能SOC动态 + 边界
29     # C4: EV SOC动态 + 离站需求
30     # C5: 柔性负荷约束
31
32     result = linprog(c, A_ub=A, b_ub=b,
33                     A_eq=Aeq, b_eq=beq,
34                     bounds=bounds, method='highs')
35     return result

```

A.2 MPC 滚动调度

Listing 2 MPC 滚动调度核心代码 (rolling_dispatch.py)

```

1  def mpc_rolling_dispatch(data, params, scenarios):
2      """MPC滚动调度主循环"""
3      T = data['n_steps']
4      Hp = params['horizon'] # 16步
5      Hc = params['control'] # 4步
6
7      schedule = np.zeros((T, n_vars_per_step))
8      soc_bat = params['soc_init']
9
10     for t0 in range(0, T, Hc):
11         # 观测实际状态
12         state = observe_state(t0, soc_bat, data)
13
14         # 更新预测 (指数平滑)
15         forecast = update_forecast(t0, Hp, data, state)
16
17         # 生成场景 (LHS + 缩减)
18         scenes = generate_scenarios(forecast,
19                                   params['n_scenarios'])
20
21         # 求解两阶段随机规划
22         x_first, _ = solve_two_stage(
23             state, forecast, scenes, params)
24

```

```

25     # 执行前  $H_c$  步决策
26     for k in range(min( $H_c$ ,  $T - t_0$ )):
27         schedule[t0+k] = x_first[k]
28         soc_bat = update_soc(soc_bat, x_first[k])
29
30     return schedule

```

A.3 Stackelberg 博弈求解

Listing 3 Stackelberg 博弈补偿优化 (compensation.py)

```

1  def stackelberg_equilibrium(ev_data, params):
2      """求解Stackelberg博弈均衡补偿水平"""
3      comp_levels = np.arange(0.3, 2.01, 0.1)
4      results = []
5
6      for comp in comp_levels:
7          # 下层：车主参与决策
8          participants = []
9          for ev in ev_data:
10             total_cost = (ev['deg_cost'] +
11                           ev['delay_cost'] +
12                           ev['anxiety_cost'] +
13                           ev['opportunity_cost'])
14             threshold = np.random.lognormal(
15                 np.log(5), 0.5)
16             if comp * ev['discharge_kwh'] >= \
17                 total_cost + threshold:
18                 participants.append(ev['id'])
19
20         # 上层：园区调度优化
21         schedule = optimize_with_v2b(
22             participants, params)
23
24         # 计算净收益
25         grid_saving = calc_grid_saving(schedule)
26         total_comp = comp * sum(
27             ev['discharge_kwh']
28             for ev in ev_data
29             if ev['id'] in participants)
30         net_benefit = grid_saving - total_comp
31

```

```
32     results.append({
33         'compensation': comp,
34         'participation_rate': len(participants)
35                               / len(ev_data),
36         'net_benefit': net_benefit
37     })
38
39     # 选择净收益最大的补偿水平
40     optimal = max(results, key=lambda x: x['net_benefit'])
41     return optimal
```