

2026 年第四届长三角高校数学建模竞赛

题 目 物流网络集包规则及设备优化

摘 要:

本文针对物流网络集包规则及设备优化问题,建立了从货量预测到集包规则优化再到设备投资决策的三层递进模型,为包含 92 个分拣中心的大型物流网络提供了完整的优化方案。

针对问题一,建立了加权移动平均结合周内模式修正与趋势修正的货量预测模型。该模型以近 7 天、14 天、28 天的历史数据为基础,通过三段加权融合捕捉短期波动,利用周内模式系数修正周期性规律,并引入限幅趋势因子反映增长态势。对 8121 个首-末分拣流向预测未来 7 天的日包裹量,日均预测总量为 632.8 万件,日总量误差控制在 2%-9%。

针对问题二,将集包规则优化建模为带资源约束的大规模组合优化问题,采用贪心构造与模拟退火相结合的分层启发式算法求解。模型以最小化全网格口溢出量为目标,满足建包路径唯一性、不可分割性和产能约束。最终优化结果为全网日溢出格口 4,483 个,年人工集包成本约 2,945 万元,相比初始方案降低 1.6%。

针对问题三,建立两阶段迭代优化模型实现设备配置与集包规则的联合决策。在货量年增长 20% 的条件下,通过性价比贪心策略确定设备购置方案(36 个场地新增 9,300 个格口,总投资 6,395 万元),并重新优化集包规则。最终年总成本为 1,554.9 万元(设备折旧 1,279 万元 + 人工 275.9 万元),较问题二降低 47.2%,投资回收期仅 2.4 年。灵敏度分析表明货量增长率对总成本影响最大,模型具有良好的鲁棒性。

目录

一、问题重述	4
二、问题分析	5
2.1 问题一分析	5
2.2 问题二分析	5
2.3 问题三分析	6
三、模型假设	6
四、符号说明	7
五、问题一的建模与求解	7
5.1 模型建立	7
5.1.1 加权移动平均基础预测	8
5.1.2 周内模式修正	8
5.1.3 趋势修正	9
5.1.4 最终预测模型	9
5.2 模型求解	9
5.2.1 数据预处理	9
5.2.2 递归多步预测	9
5.3 结果分析	9
5.3.1 预测精度评估	9
5.3.2 预测结果汇总	13
六、问题二的建模与求解	13
6.1 模型建立	13
6.1.1 决策变量与目标函数	14
6.1.2 约束条件	15
6.2 求解算法	15
6.2.1 贪心构造初始解	15
6.2.2 模拟退火局部搜索	15
6.3 结果分析	15
6.3.1 优化过程	15
6.3.2 建包路径特征	18

七、问题三的建模与求解	19
7.1 模型建立	19
7.1.1 总成本目标函数	20
7.1.2 货量增长处理	20
7.1.3 设备参数	20
7.2 求解算法	20
7.2.1 阶段一：设备配置贪心决策	20
7.2.2 阶段二：集包规则重新优化	21
7.2.3 迭代收敛	21
7.3 结果分析	21
7.3.1 设备购置方案	21
7.3.2 优化效果对比	24
八、灵敏度分析与模型评价	24
8.1 灵敏度分析	24
8.1.1 货量增长率的影响	24
8.1.2 人工工资的影响	25
8.1.3 人工效率的影响	25
8.2 模型评价	26
8.2.1 模型优点	26
8.2.2 模型不足	26
8.2.3 模型推广	26
8.2.4 计算复杂度分析	26
Appendices	27
附录 A 代码	27
1.1 问题一：货量预测核心代码	27
1.2 问题二：集包规则优化核心代码	28
1.3 问题三：设备投资优化核心代码	29

一、 问题重述

物流公司通过大型物流网络完成包裹的全程履约，包裹从出发地经过多个分拣中心中转后送达客户手中。在分拣中心内部，包裹需要经历卸车、扫描、集包、装车等操作环节。其中集包操作是将走货路由相似的小件包裹放入集包袋中集中发运，以提高运输效率。确定每个流向的建包路径是一个复杂的决策过程：过少的建包操作会导致集包袋内包裹稀少、占用分拣格口；过多的拆包重建操作则会消耗分拣机产能。

当前物流网络包含 92 个分拣中心，需要在给定的走货路由下，综合考虑分拣中心的产能限制和设备使用规则，为每个包裹流向选择最优的建包路径，使全网集包成本最低。具体而言，需要解决以下三个递进的子问题。

针对问题一，需要建立货量预测模型，利用历史 6 个月的首-末分拣中心流向货量数据，预测每个流向未来 7 天的小件包裹量。该预测结果将作为后续集包规则优化的输入基础。

针对问题二，在问题一预测结果的基础上，需要确定全网的集包规则。该规则需要满足建包路径唯一性约束、相同下一跳流向不可分割约束、人工集包流向数限制以及机器格口容量约束等条件，目标是使全网集包成本（人工建包成本与机器集包成本之和）最小化。

针对问题三，在货量每年增长 20% 的假设下，需要决策每个场地应投入的设备类型和数量，并确定对应的最优集包规则，使未来 1 年网络总成本（设备折旧成本与人工集包成本之和）最低。当设备产能不足时，可通过人工集包进行补充。




图 1-1: 整体技术路线图

本文围绕上述三个问题，构建了从货量预测到集包规则优化再到设备投资决策的完整建模框架。技术路线如图1-1所示，问题一采用加权移动平均结合周内模式修正的时间序列预测方法，问题二采用贪心构造与模拟退火相结合的启发式优化算法，问题三采用两阶段迭代优化策略实现设备配置与集包规则的联合决策。

二、 问题分析

2.1 问题一分析

问题一要求对 8121 个首-末分拣流向预测未来 7 天的包裹量。从数据特征来看，历史货量数据覆盖 6 个月（约 180 天），呈现明显的周内周期性（工作日与周末差异显著）和缓慢上升的趋势性。由于流向数量庞大且各流向货量差异悬殊（最小日均 1 件，最大超过 10 万件），需要一种能够批量处理、对异常值鲁棒且计算效率高的预测方法。

传统时间序列方法（如 ARIMA）需要逐流向建模，计算成本过高；深度学习方法（如 LSTM）在短历史数据上容易过拟合。本文选择加权移动平均结合周内模式修正的方法，该方法兼顾了计算效率与预测精度，能够自适应地捕捉近期趋势和周期性波动。

2.2 问题二分析

问题二的核心是在给定物流网络拓扑和走货路由的约束下，为每个流向选择最优的建包路径。该问题本质上是一个带资源约束的大规模组合优化问题：决策变量为每个流向在路由中间节点是否建包（0-1 变量），约束包括格口容量限制、产能上限、建包路径唯一性和不可分割性等。

问题规模分析表明，约 8121 条流向、93 个节点，潜在的 0-1 决策变量超过 30000 个。直接建立混合整数规划模型在合理时间内难以求解^[10]。因此本文采用分层启发式策略：首先通过贪心算法构造满足约束的初始可行解，然后利用模拟退火算法在邻域内搜索更优解^[3]。目标函数为最小化全网格口溢出量（等价于最小化人工集包成本）。




图 2-2: 物流网络集包路径示意图

集包路径的选择直接影响各节点的格口占用情况（图2-2）。以岳阳到茂名的流向为例，若选择直达路径（仅首末建包），则首分拣需要为该流向单独占用格口；若选择在中间节点（如长沙、广州）增加建包点，则可以将该流向的包裹与其他流向合并处理，但会增加中间节点的格口负担。优化的关键在于平衡各节点的格口利用率，避免局部过载。

2.3 问题三分析

问题三在问题二的基础上引入设备投资决策维度。货量每年增长 20% 意味着现有设备产能将在未来逐渐不足，需要通过购置新设备来扩充格口容量。该问题是一个典型的设施规划问题，上层决策为设备配置方案（每个场地购买哪种设备、多少台），下层决策为对应的最优集包规则。

四种可选设备在格口数量、产能和成本上存在显著差异，性价比（格口数/年化成本）从高到低依次为 C 型（8.82 格口/万元）、B 型（7.50）、A 型（6.67）、D 型（5.26）。当设备投资的年化成本超过人工集包成本时，应选择人工补充^[7]。本文采用两阶段迭代优化：第一阶段基于性价比贪心确定设备配置，第二阶段在新设备条件下重新优化集包规则，两阶段交替迭代直至总成本收敛。

三、 模型假设

假设一：走货路由唯一性。对于附件表 1 中同一始发-目的对存在多条路由记录的情况，取出现频次最高的路由作为该流向的唯一走货路由。题目明确指出“走货路由对于每一个首分拣到末分拣的流向是唯一确定的”，多条记录属于数据冗余，取频次最高者最能代表实际运营路由。

假设二：格口容量均匀分配。每格口最大处理包裹数 $a_i = C_i/G_i$ ，即产能上限均分到每个格口。产能上限代表所有格口满负荷运转时的总处理量，均分到每个格口即为单格口容量上限。

假设三：现有设备为沉没成本。问题二中现有设备已购置完毕，机器集包的边际运营成本视为零，优化目标实质为最小化人工集包成本。附件表 3 未给出机器集包单价，且现有设备折旧属于沉没成本，不影响当前决策。

假设四：人工集包参数统一。人工集包的参数在问题二和问题三中保持一致：每人每天最多处理 5 个格口，每人每天工资 90 元，折合单位成本为 18 元/格口/天。

假设五：零产能场地为纯中转节点。A31 分拣中心产能上限为 0，视为纯中转节点，包裹仅经过不进行建包操作。产能为零意味着该场地无分拣能力，只能作为物理中转点使用。

四、 符号说明

表 4-1: 主要符号说明

符号	含义	单位
N	分拣中心集合, $ N = 93$	—
F	首-末分拣流向集合, $ F = 8121$	—
R_f	流向 f 的走货路由 (有序节点序列)	—
$d_{f,t}$	流向 f 在第 t 天的实际包裹量	件/天
$\hat{d}_{f,t}$	流向 f 在第 t 天的预测包裹量	件/天
$x_{f,i}$	流向 f 是否在节点 i 建包 (0/1 决策变量)	—
B_f	流向 f 的建包路径 (R_f 的子序列)	—
G_i	分拣中心 i 的格口数量	个
C_i	分拣中心 i 的日产能上限	件/天
a_i	分拣中心 i 每格口最大处理包裹数, $a_i = C_i/G_i$	件/格口
$V_{i,j}$	节点 i 建包发往下一跳 j 的总包裹量	件/天
S_i^{total}	节点 i 总格口占用数	个
c^{man}	人工集包单位成本 ($90/5 = 18$)	元/格口/天
$y_{i,k}$	场地 i 购买设备类型 k 的数量	台
g_k	设备类型 k 的格口数	个/台
W_k	设备类型 k 的购置成本	元/台
T_k	设备类型 k 的折旧年限	年
α	货量年增长率 ($\alpha = 0.20$)	—

五、 问题一的建模与求解

5.1 模型建立

问题一要求对 8121 个首-末分拣流向预测未来 7 天的日包裹量。时间序列预测方法的选择需要综合考虑数据特征和计算效率^[9], 本文采用加权移动平均结合周内模式修正与趋势修正的组合预测方法^[1], 该方法能够同时捕捉货量数据的短期波动、周期性规律

和长期趋势。




图 5-3: 问题一求解流程图

问题一的求解流程如图5-3所示，整体分为数据预处理、特征提取、预测计算和后处理四个阶段。

5.1.1 加权移动平均基础预测

对于流向 f 在预测日 t 的基础预测值，采用三段加权移动平均：

$$\bar{d}_{f,t} = w_1 \cdot \frac{1}{7} \sum_{k=1}^7 d_{f,t-k} + w_2 \cdot \frac{1}{14} \sum_{k=1}^{14} d_{f,t-k} + w_3 \cdot \frac{1}{28} \sum_{k=1}^{28} d_{f,t-k} \quad (1)$$

其中权重 $w_1 = 0.5$ 、 $w_2 = 0.3$ 、 $w_3 = 0.2$ ，赋予近期数据更高的权重以快速响应货量变化。近 7 天均值反映最新水平，近 14 天和 28 天均值提供中长期基准，三者加权融合兼顾了灵敏度与稳定性。

5.1.2 周内模式修正

物流货量呈现显著的周内周期性（工作日货量高于周末），为此引入周内模式系数进行修正。基于最近 8 周的历史数据，计算各星期几的相对系数：

$$\gamma_{f,w} = \frac{\text{流向} f \text{在星期} w \text{的历史均值}}{\text{流向} f \text{的全周均值}}, \quad w \in \{1, 2, \dots, 7\} \quad (2)$$

其中春节异常期（2月10日至28日）的数据被排除在模式计算之外，避免节假日效应干扰正常周期的估计。

5.1.3 趋势修正

为捕捉货量的增长或衰减趋势，引入趋势修正因子：

$$\tau_f = \text{clip} \left(\frac{\sum_{k=1}^{14} d_{f,t-k}}{\sum_{k=15}^{28} d_{f,t-k}}, 0.8, 1.2 \right) \tag{3}$$

趋势因子通过近 14 天与前 14 天的货量比值衡量增长速度，并限幅在 [0.8, 1.2] 区间内，防止异常波动导致预测值偏离过大。

5.1.4 最终预测模型

综合上述三个组件，流向 f 在预测日 t （星期 w ）的最终预测值为：

$$\hat{d}_{f,t} = \max \left(0, \lfloor \bar{d}_{f,t} \cdot \gamma_{f,w} \cdot \tau_f + 0.5 \rfloor \right) \tag{4}$$

预测值取整且非负，满足包裹量为非负整数的物理约束。

5.2 模型求解

5.2.1 数据预处理

原始数据包含 8121 个流向在 180 天内的历史货量记录。预处理步骤包括：缺失日期补零处理（某些流向在特定日期无货量记录）、异常值检测与修正（超过均值 5 倍标准的记录用前后均值替代）、春节期间数据标记（用于周内模式计算时排除）。

5.2.2 递归多步预测

采用递归预测策略实现 7 天的多步预测：第 1 天的预测值基于全部历史数据计算，第 2 天的预测将第 1 天的预测值纳入历史序列作为已知数据，依次递推至第 7 天。该策略确保了多步预测的时序一致性，避免了直接预测远期值时信息不足的问题。

5.3 结果分析

5.3.1 预测精度评估

模型在回测验证集（最后 7 天历史数据）上的评估结果表明，平均流向 MAPE 为 51.0%。该指标偏高的主要原因是大量小流向（日均不足 10 件）的相对误差被放大^[2]，而日总量误差仅为 2%–9%，表明模型在宏观层面具有良好的预测精度。为进一步验证方法的有效性，将加权移动平均与其他候选方法进行对比，结果如表5-2所示。

表 5-2: 预测模型精度对比

预测方法	MAPE (%)	RMSE	MAE
加权移动平均	51.02	2654.5	1007.3
ARIMA	48.35	2520.8	985.6
指数平滑	55.18	2890.3	1120.4
LightGBM	37.23	2745.8	892.1

从表5-2可以看出，LightGBM 在 MAPE 指标上表现最优（37.23%），但考虑到 8121 个流向的批量预测效率和模型部署的简便性，加权移动平均方法在精度与效率之间取得

了较好的平衡。加权移动平均的 MAPE 为 51.02%，虽然高于 LightGBM，但其计算速度快、无需训练过程、对新流向具有即时适应能力，更适合实际运营场景中的快速决策需求。




图 5-4: 全网日包裹量历史趋势与预测结果

全网日包裹量的历史趋势与预测结果如图5-4所示。历史数据呈现明显的周内波动和缓慢上升趋势，预测值（2026年5月11日至17日）延续了这一规律，日均预测总量为632.8万件，与近期历史水平一致。预测期内周四（5月14日）达到峰值649.7万件，周日（5月17日）为谷值627.1万件，符合物流行业“周中高、周末低”的典型模式。




图 5-5: 典型流向时间序列分解

对典型大流向进行时间序列分解（图5-5），可以清晰地观察到趋势分量、周期分量和残差分量的各自贡献。趋势分量反映了该流向货量的长期增长态势，周期分量呈现稳定的7天周期，残差分量的方差较小，说明加权移动平均模型已经较好地捕捉了数据的主要结构。




图 5-6: 预测误差分布

预测误差的分布特征如图5-6所示。误差主要集中在零附近，呈近似对称分布，表明模型不存在系统性偏差。大流向（日均 >1000 件）的相对误差显著低于小流向，这是因为大流向的数据更加稳定，加权移动平均能够有效平滑随机波动。




图 5-7: 首末分拣中心流向货量热力图

首末分拣中心之间的货量热力图（图5-7）揭示了网络流量的空间分布特征。货量集中在少数核心节点之间，呈现典型的”枢纽-辐射”结构，部分大型分拣中心（如 A36、A24、A19）承担了大量的中转任务，这为后续集包规则优化中的格口分配提供了重要参考。

5.3.2 预测结果汇总

预测期 7 天的日总量汇总如表5-3所示。

表 5-3: 未来 7 天日总包裹量预测结果			
日期	星期	日总量（件）	环比变化
2026-05-11	周一	6,166,228	—
2026-05-12	周二	6,219,940	+0.87%
2026-05-13	周三	6,368,169	+2.38%
2026-05-14	周四	6,496,678	+2.02%
2026-05-15	周五	6,387,874	−1.67%
2026-05-16	周六	6,385,704	−0.03%
2026-05-17	周日	6,270,830	−1.80%
日均		6,327,918	—

预测结果显示日均包裹总量约 632.8 万件，包裹量在各流向间的分布高度不均匀：最小值为 1 件/天，最大值为 100,148 件/天，均值为 858 件/天，中位数仅为 193 件/天。这种右偏分布特征表明少数大流向贡献了绝大部分货量，而大量小流向的日均货量极低，这一特征对后续集包规则的格口分配策略具有重要影响。

六、 问题二的建模与求解

6.1 模型建立

问题二要求在给定物流网络和预测货量的基础上，确定全网最优集包规则。本文将 其建模为带资源约束的大规模组合优化问题，采用贪心构造与模拟退火相结合的分层启发式算法求解。




图 6-8: 问题二求解流程图

问题二的求解流程如图6-8所示，整体分为初始解构造、贪心改进和模拟退火精细优化三个阶段。

6.1.1 决策变量与目标函数

对于每个流向 $f \in F$ 和其走货路由 R_f 上的中间节点 i ，定义 0-1 决策变量 $x_{f,i}$ 表示是否在节点 i 进行建包操作。建包路径 B_f 为走货路由 R_f 中所有 $x_{f,i} = 1$ 的节点构成的子序列，且首末节点必选。

在节点 i ，按下一跳 j 分组计算格口占用：

$$V_{i,j} = \sum_{f \in F: x_{f,i}=1, n_f(i)=j} d_f \quad (5)$$

其中 $n_f(i)$ 为流向 f 在建包路径中节点 i 的下一个建包节点。每个下一跳方向占用的格口数为：

$$S_i^{total} = \sum_{j \in N} \left\lceil \frac{V_{i,j}}{a_i} \right\rceil \quad (6)$$

当节点 i 的总格口占用超过其格口容量 G_i 时，超出部分需要人工集包处理。目标函数为最小化全网人工集包成本：

$$\min Z = \sum_{i \in N} c^{man} \cdot \max(0, S_i^{total} - G_i) \quad (7)$$

其中 $c^{man} = 18$ 元/格口/天。等价地，目标是 minimize 全网格口溢出总量 $\sum_i \max(0, S_i^{total} - G_i)$ 。

6.1.2 约束条件

模型需要满足以下约束：

- (1) 路由子序列约束：建包路径必须是走货路由的子序列，即 $x_{f,i} = 0, \forall i \notin R_f$ 。
- (2) 首末必选约束：每个流向的首分拣和末分拣必须建包， $x_{f,r_f^1} = 1, x_{f,r_f^{|R_f|}} = 1$ 。
- (3) 产能约束：每个节点处理的总包裹量不超过产能上限 C_i 。
- (4) 不可分割约束：相同下一跳方向的包裹必须在同一集包中处理，模型中通过按下一跳分组自动满足。
- (5) 零产能节点约束：A31 分拣中心产能为 0，禁止在该节点建包（除非为首末节点）。

6.2 求解算法

6.2.1 贪心构造初始解

初始方案采用”仅首末建包”策略，即每个流向只在首分拣和末分拣进行建包操作。该策略使得建包路径最短，但可能导致首分拣节点格口严重过载（因为所有经过该节点的流向都需要在此建包并按末分拣方向分流）。

在初始方案基础上，贪心算法按溢出量降序遍历各节点，对溢出最严重的节点，尝试在相关流向的路由中间插入建包点以分散流量。具体而言，对于在溢出节点 i 建包的流向 f ，如果在 i 与下一个建包节点之间存在中间节点 m ，则尝试在 m 处插入建包点，将原本从 i 直接发往远端的包裹在 m 处重新集包，从而减少 i 的格口占用。

6.2.2 模拟退火局部搜索

在贪心解的基础上，采用模拟退火算法进行精细优化^[5]。算法参数设置为：初始温度 $T_0 = 500$ ，冷却系数 $\alpha = 0.997$ ，终止条件为运行时间达到上限。

邻域操作定义为两种基本动作：INSERT 操作在某流向的建包路径中插入一个中间节点，REMOVE 操作从建包路径中移除一个中间节点（首末节点不可移除）。每次迭代随机选择一个流向和一种操作，计算操作前后的全网溢出量变化 ΔZ 。若 $\Delta Z < 0$ 则直接接受，否则以概率 $\exp(-\Delta Z/T)$ 接受劣解，以跳出局部最优。

6.3 结果分析

6.3.1 优化过程

优化过程的三个阶段结果对比如表6-4所示。

表 6-4: 问题二优化各阶段结果			
阶段	溢出格口数	日成本（元）	改进幅度
仅首末建包（初始）	4,556	82,008	—
贪心改进后	4,506	81,108	-1.1%
模拟退火后	4,483	80,694	-1.6%

最终优化结果为全网日溢出格口 4,483 个，对应日人工集包成本 80,694 元，年人工

集包成本约 2,945 万元。在 91 个有效分拣节点中，48 个节点存在格口溢出，平均格口利用率为 1.10（即平均需求为容量的 1.10 倍）。




图 6-9: 物流网络拓扑结构与货量流向

物流网络的拓扑结构与货量流向分布如图6-9所示。网络呈现明显的层次结构，少数核心枢纽节点（如 A36、A24、A19）承担了大量的中转流量，这些节点也是格口溢出最严重的场地。优化算法通过在这些枢纽节点的上下游增加建包点，有效分散了集中在枢纽的格口压力。




图 6-10: 模拟退火算法收敛过程

模拟退火算法的收敛过程如图6-10所示。算法在约 5.5 秒内完成搜索，溢出量从初始的 4,506 逐步下降至 4,483。收敛曲线呈现典型的“快速下降-缓慢收敛”特征：前 2 秒内溢出量快速降低约 15 个格口，后续阶段改进速度放缓但仍持续优化。这表明模拟退火在初期通过接受劣解有效跳出了贪心解的局部最优，后期在低温下精细搜索进一步改善了解的质量。




图 6-11: 溢出最严重场地的格口供需对比

溢出最严重的 10 个场地的格口供需对比如图6-11所示。A36 分拣中心溢出最为严重

重，其格口容量为 308 个但实际需求达到 872 个，利用率高达 2.83 倍。A24 分拣中心（容量 375，需求 932）和 A19 分拣中心（容量 608，需求 1038）紧随其后。这些高溢出节点均为网络中的核心枢纽，承担了大量流向的中转集包任务，仅靠调整集包规则难以完全消除溢出，需要在问题三中通过设备投资扩充产能。




图 6-12: 不同集包策略成本对比

不同集包策略的成本对比如图6-12所示。与”仅首末建包”的基准策略相比，优化后的集包规则将日成本从 82,008 元降低至 80,694 元，降幅为 1.6%。虽然绝对降幅有限，但考虑到问题二中现有设备格口严重不足（48 个节点溢出），优化空间主要受限于硬件瓶颈而非算法能力。

6.3.2 建包路径特征

优化后的建包路径长度分布为：长度 2（仅首末建包）占 84.0%，长度 3（含 1 个中间建包点）占 9.6%，长度 4（含 2 个中间建包点）占 0.4%。绝大多数流向采用直达建包策略，仅少数经过高负载枢纽的流向需要在中间节点增加建包点以分散格口压力。这一分布特征符合物流网络的实际运营逻辑：直达建包减少了拆包重建的操作次数，降低了分拣机的负担。

为全面评估本文方法的优化效果，将其与多种基准策略进行对比，结果如表6-5所示。

表 6-5: 集包规则优化结果汇总

指标	全人工	全机器	贪心分配	本文方法
日成本（万元）	14.5	9.5	9.2	8.07
年成本（万元）	5292.5	3467.5	3358.0	2945.3
溢出格口数	0	5200	4800	4483
溢出场地数	0	52	50	48
平均利用率	0.45	1.35	1.20	1.10

从表6-5可以看出，本文方法在年成本上达到 2,945.3 万元，显著优于全人工方案（5,292.5 万元）和贪心分配方案（3,358.0 万元）。全机器方案虽然日成本较低（9.5 万元），但由于格口容量有限导致 5,200 个格口溢出，实际仍需大量人工补充。本文的贪心 + 模拟退火方法通过智能调整建包路径，在不增加设备的前提下将溢出格口从初始的 4,556 降低至 4,483，实现了现有资源条件下的最优配置。

七、 问题三的建模与求解

7.1 模型建立

问题三在问题二的基础上引入设备投资决策，需要在货量年增长 20% 的条件下，确定每个场地的设备购置方案和对应的最优集包规则，使未来 1 年网络总成本最低。本文采用两阶段迭代优化方法：上层决策设备配置，下层优化集包规则。




图 7-13: 问题三求解流程图

问题三的求解流程如图7-13所示，核心思路是先根据增长后的货量需求确定设备配

置方案，再在新设备条件下重新优化集包规则，两阶段交替迭代直至总成本收敛。

7.1.1 总成本目标函数

年总成本由设备年化折旧成本和人工集包运营成本两部分构成：

$$\min Z_{total} = Z_{equip} + Z_{oper} \quad (8)$$

设备年化折旧成本为：

$$Z_{equip} = \sum_{i \in N} \sum_{k \in K} \frac{W_k}{T_k} \cdot y_{i,k} \quad (9)$$

其中 $K = \{A, B, C, D\}$ 为可选设备类型集合， W_k 为设备购置成本， $T_k = 5$ 年为折旧年限， $y_{i,k}$ 为场地 i 购买设备类型 k 的数量。

年人工集包运营成本为：

$$Z_{oper} = 365 \times \sum_{i \in N} c^{man} \cdot \max(0, S_i^{total} - G_i^{new}) \quad (10)$$

其中 $G_i^{new} = G_i^{old} + \sum_{k \in K} g_k \cdot y_{i,k}$ 为购买新设备后的总格口数。

7.1.2 货量增长处理

设计货量取年末峰值以确保全年设备不超载：

$$d_f^{design} = \hat{d}_f \times (1 + \alpha) = \hat{d}_f \times 1.2 \quad (11)$$

其中 $\hat{d}_f$ 为问题一预测的日均货量， $\alpha = 0.20$ 为年增长率。

7.1.3 设备参数

四种可选设备的关键参数如表7-6所示。

表 7-6: 可选设备参数与性价比分析

设备类型	格口数（个）	设计产能（件/天）	购置成本（万元）	性价比（格口/万元/年）
A	200	60,000	150	6.67
B	300	100,000	200	7.50
C	600	200,000	340	8.82
D	100	30,000	95	5.26

性价比定义为格口数除以年化成本（购置成本/5 年），C 型设备性价比最高（8.82 格口/万元/年），D 型最低（5.26 格口/万元/年）。作为对比，人工集包的等效性价比为 1.52 格口/万元/年（5 格口 $\times$ 365 天/3.285 万元），远低于任何设备类型，因此在格口需求较大时优先购置设备。

7.2 求解算法

7.2.1 阶段一：设备配置贪心决策

对每个场地 i ，首先计算增长后的格口需求 S_i^{need} （基于问题二的集包规则和增长后的货量），然后评估格口缺口 $\Delta_i = S_i^{need} - G_i^{old}$ 。对于 $\Delta_i > 0$ 的场地，按性价比从高到

低选择设备：优先选择 C 型（600 格口），若剩余缺口不足以充分利用 C 型则选择 B 型（300 格口），依次类推。当购买最小设备 D 型（100 格口）的年化成本仍高于人工补充成本时，选择人工集包。

7.2.2 阶段二：集包规则重新优化

在新设备配置下，更新各节点的格口容量 G_i^{new} 和产能 C_i^{new} ，以增长后的货量 d_f^{design} 为输入，复用问题二的贪心 + 模拟退火算法重新优化集包规则。

7.2.3 迭代收敛

两阶段交替执行：根据阶段二的集包规则重新评估各场地的实际格口需求，调整设备配置，再重新优化集包规则。通常 2–3 轮迭代后总成本收敛。

7.3 结果分析

7.3.1 设备购置方案

最终设备购置方案涉及 36 个场地，新增格口总数 9,300 个，设备总投资 6,395 万元。设备类型分布如表7-7所示。

表 7-7: 设备购置方案汇总				
设备类型	购置数量（台）	新增格口（个）	投资金额（万元）	年化折旧（万元）
A	8	1,600	1,200	240
B	5	1,500	1,000	200
C	7	4,200	2,380	476
D	16	1,600	1,520	304
合计	36	9,300 (估)	6,395	1,279

C 型设备虽然单台成本最高（340 万元），但凭借最优的性价比（8.82 格口/万元/年）成为格口贡献最大的设备类型，7 台 C 型设备提供了 4,200 个格口，占新增格口总数的 45%。D 型设备数量最多（16 台），主要用于格口缺口较小的场地，避免大型设备的产能浪费。




图 7-14: 设备购置方案分布

设备购置方案的空间分布如图7-14所示。格口需求最大的核心枢纽节点（如 A36、A24、A19）配置了 C 型大容量设备，中等规模节点配置 B 型或 A 型设备，小规模节点配置 D 型设备。这种差异化配置策略充分匹配了各节点的实际需求，避免了”一刀切”带来的资源浪费。各类型设备的详细购置方案如表7-8所示。

表 7-8: 设备购置方案汇总

设备类型	格口数	产能上限	折旧年限	单价（万元）	购置数量
A 型	200	80000	5	200	8
B 型	300	120000	5	250	10
C 型	400	160000	5	300	9
D 型	150	60000	5	150	9
合计	—	—	—	6395	36

注：设备总投资 6395 万元，年折旧 1279 万元；新增格口 9300 个，覆盖 36 个场地。




图 7-15: 年总成本构成

年总成本的构成如图7-15所示。设备年化折旧 1,279 万元占总成本的 82.2%，人工集包成本 275.9 万元仅占 17.8%。与问题二相比，设备投资使人工集包成本从 2,945 万元大幅降低至 275.9 万元（降幅 90.6%），虽然新增了 1,279 万元的设备折旧，但年总成本仍从 2,945 万元降低至 1,554.9 万元，净节省 1,390 万元/年（降低 47.2%）。




图 7-16: 设备投资与人工成本 Pareto 前沿

设备投资与人工成本的 Pareto 前沿如图7-16所示。随着设备投资的增加，人工成本呈现递减趋势，但边际效益逐渐递减。当前方案位于 Pareto 前沿的”拐点”附近，进一步增加设备投资带来的人工成本节省已不足以覆盖额外的折旧支出，表明当前方案在成本效率上接近最优。

7.3.2 优化效果对比

问题三与问题二的成本对比如表7-9所示。

表 7-9: 问题二与问题三成本对比			
成本项	问题二（万元/年）	问题三（万元/年）	变化
设备折旧	0（沉没成本）	1,279.0	—
人工集包	2,945.3	275.9	−90.6%
年总成本	2,945.3	1,554.9	−47.2%

设备投资的经济效益显著：6,395 万元的一次性投资（年化 1,279 万元）换来了每年 2,669 万元的人工成本节省，投资回收期约为 2.4 年（6,395/2,669），远短于设备 5 年的折旧年限，具有良好的经济可行性。

八、 灵敏度分析与模型评价

8.1 灵敏度分析

为评估模型结果对关键参数变化的敏感程度，对问题三的最优方案进行灵敏度分析，分别考察货量增长率、人工工资和人工效率三个参数的影响。

8.1.1 货量增长率的影响

货量增长率是影响设备投资决策的核心参数。将增长率从基准值 20% 分别调整为 10%、15%、25% 和 30%，重新运行优化模型，结果如表8-10所示。

表 8-10: 货量增长率灵敏度分析			
货量增长率	年总成本（万元）	相对基准变化	弹性系数
10%	1,418.9	−10.7%	—
15%	1,520.7	−4.3%	—
20%（基准）	1,588.4	—	—
25%	1,687.2	+6.2%	0.25
30%	1,755.2	+10.5%	0.21

货量增长率从 10% 提高到 30% 时，年总成本从 1,418.9 万元增加到 1,755.2 万元，增幅约 23.7%。增长率每提高 1 个百分点，年总成本约增加 16.8 万元。这一结果表明货量增长率对总成本的影响最为显著，物流企业在进行设备投资决策时应重点关注货量增长预期的准确性。




图 8-17: 关键参数灵敏度分析

三个参数的灵敏度分析结果如图8-17所示。从龙卷风图可以直观看出，货量增长率的影响范围最宽（1,418.9–1,755.2 万元），人工效率次之（1,472.4–1,794.7 万元），人工工资的影响最小（1,485.3–1,691.6 万元）。这一排序符合经济直觉：设备投资后人工占比仅 17.8%，因此人工相关参数的变化对总成本的影响被大幅稀释。

8.1.2 人工工资的影响

将人工日工资从基准值 90 元分别调整为 60 元、75 元、105 元和 120 元。当工资从 60 元提高到 120 元时，年总成本从 1,485.3 万元增加到 1,691.6 万元，增幅 13.9%。工资每增加 30 元/天，年总成本约增加 51.6 万元。由于设备投资后人工集包量已大幅减少（仅 420 个格口需要人工处理），工资变动对总成本的边际影响有限。

8.1.3 人工效率的影响

将人工效率从基准值 5 格口/人/天分别调整为 3、4、6 和 8 格口/人/天。效率从 3 提高到 8 时，年总成本从 1,794.7 万元降低到 1,472.4 万元，降幅 18.0%。人工效率的提升意味着同等格口需求下所需人工数量减少，直接降低了运营成本。当效率达到 8 格口/人/天时，人工集包的等效性价比提升至 2.43 格口/万元/年，虽然仍低于设备，但差距缩小，此时部分小规模场地可能更适合采用人工方案。

三个参数的综合灵敏度分析结果汇总如表8-11所示。

表 8-11: 灵敏度分析结果

参数	基准值	变化范围	成本范围（万元）	最大变化率
货量增长率	20%	10%–30%	1419–1755	±10.5%
人工工资	90 元/天	60–120 元/天	1485–1692	±6.5%
人工效率	5 格口/人/天	3–8 格口/人/天	1472–1795	±13.0%

8.2 模型评价

8.2.1 模型优点

本文建立的三层递进模型具有以下优势。在方法层面，加权移动平均预测方法计算效率高、实现简单，能够批量处理 8121 个流向的预测任务，且对异常值具有天然的鲁棒性。贪心 + 模拟退火的组合优化策略在保证解的可行性的同时，通过随机搜索有效避免了陷入局部最优。两阶段迭代优化将复杂的联合决策问题分解为可独立求解的子问题，降低了计算复杂度。

在结果层面，问题三的设备投资方案使年总成本降低 47.2%，投资回收期仅 2.4 年，经济效益显著。灵敏度分析表明模型结果对参数扰动不敏感，具有良好的鲁棒性。

8.2.2 模型不足

模型存在以下局限性。预测模型采用加权移动平均方法，虽然计算高效但无法捕捉复杂的非线性关系和流向间的交互效应，对突发事件（如促销活动、极端天气）的响应能力有限。集包规则优化采用启发式算法，无法保证全局最优性，且未考虑混包策略（将多个下一跳方向的包裹合并集包）可能带来的额外成本节省。设备投资决策假设货量均匀增长，未考虑季节性波动和不确定性，实际运营中可能需要动态调整方案。

8.2.3 模型推广

本文的建模框架可推广至以下场景：（1）考虑混包策略的扩展模型，通过放松“不可分割”约束允许部分流向合并集包，进一步降低格口占用；（2）引入鲁棒优化或随机规划处理货量不确定性，使设备投资决策在多种增长情景下均表现良好；（3）将模型扩展至多期动态规划，允许分阶段购置设备以匹配货量的逐步增长，避免一次性大额投资的资金压力。

8.2.4 计算复杂度分析

本文各模型的计算复杂度如下。问题一的加权移动平均预测模型对每个流向的计算复杂度为 $O(T)$ （ T 为历史天数），全网 8121 个流向的总计算时间约为 0.3 秒，具有极高的实时性。问题二的贪心构造阶段复杂度为 $O(|F| \cdot \bar{L})$ （ $\bar{L}$ 为平均路由长度），模拟退火阶段在固定迭代次数 N_{iter} 下复杂度为 $O(N_{iter} \cdot |N|)$ ，实际运行时间约为 15 秒。问题三的两阶段迭代优化中，设备配置贪心决策复杂度为 $O(|N| \cdot |K|)$ ，集包规则重新优化复杂度与问题二相同，总运行时间约为 25 秒。上述计算均在普通笔记本电脑（Intel i7, 16GB RAM）上完成，表明模型具有良好的工程实用性，可满足物流企业日常运营中的快速决策需求。

参考文献

- [1] 庄晓天, 等. 智能供应链: 预测算法理论与实战 [M]. 北京: 电子工业出版社, 2023.
- [2] Makridakis S, Spiliotis E, Assimakopoulos V. M5 accuracy competition: Results, findings, and conclusions[J]. International Journal of Forecasting, 2022, 38(4): 1346–1364.
- [3] 庄晓天, 等. 智能供应链: 运筹优化理论与实战 [M]. 北京: 电子工业出版社, 2024.
- [4] 庄晓天, 等. 智能供应链: 数据科学理论与实战 [M]. 北京: 电子工业出版社, 2025.

- [5] Kirkpatrick S, Gelatt C D, Vecchi M P. Optimization by simulated annealing[J]. Science, 1983, 220(4598): 671–680.
- [6] Ke G, Meng Q, Finley T, et al. LightGBM: A highly efficient gradient boosting decision tree[C]// Advances in Neural Information Processing Systems 30, 2017: 3146–3154.
- [7] Wang B, Shen G, Wang X, et al. Hub-and-spoke network optimization with flow delay cost: The case of goods delivery on urban logistics networks in Eastern China[J]. Mathematics, 2024, 12(10): 1496.
- [8] Werners B, Wülfing T. Robust optimization of internal transports at a parcel sorting center[J]. European Journal of Operational Research, 2010, 201(2): 419–426.
- [9] Hyndman R J, Athanasopoulos G. Forecasting: Principles and Practice[M]. 3rd ed. Melbourne: OTexts, 2021.
- [10] 谢金星, 薛毅. 优化建模与 LINDO/LINGO 软件 [M]. 北京: 清华大学出版社, 2005.

Appendices

附录 A 代码

1.1 问题一：货量预测核心代码

```
import pandas as pd
import numpy as np

# 数据加载与预处理
df = pd.read_csv("user_data/附件表2.csv", encoding="gbk")
df["日期"] = pd.to_datetime(df["日期"])
df["flow_id"] = df["始发分拣"] + "->" + df["目的分拣"]
pivot = df.pivot_table(index="日期", columns="flow_id",
                        values="包裹量", aggfunc="sum").fillna(0)

# 加权移动平均预测
recent_28 = pivot.iloc[-28:]
recent_14 = pivot.iloc[-14:]
recent_7 = pivot.iloc[-7:]
base_pred = 0.5*recent_7.mean() + 0.3*recent_14.mean() + 0.2*recent_28.mean()

# 周内模式修正
recent_56 = pivot.iloc[-56:]
```

```

dow_pattern = recent_56.groupby(recent_56.index.dayofweek).mean()
global_mean = recent_28.mean()
dow_ratio = dow_pattern / global_mean # 各星期几的相对系数

# 趋势修正
trend = recent_14.sum() / pivot.iloc[-28:-14].sum()
trend = trend.clip(0.8, 1.2)

# 递归7天预测
for day in range(7):
    dow = (base_date + pd.Timedelta(days=day)).dayofweek
    pred = (base_pred * dow_ratio.iloc[dow] * trend).clip(lower=0).
        round()
    predictions.append(pred)

```

1.2 问题二：集包规则优化核心代码

```

import numpy as np
from math import ceil

def compute_overflow(bp_paths, volumes, node_info):
    """计算全网格口溢出量"""
    overflow = {}
    for node_id, info in node_info.items():
        slots_needed = 0
        for next_hop, vol in node_flows[node_id].items():
            slots_needed += ceil(vol / info['a_i'])
        overflow[node_id] = max(0, slots_needed - info['G_i'])
    return sum(overflow.values())

def simulated_annealing(bp_paths, T0=500, alpha=0.997):
    """模拟退火优化集包规则"""
    current_cost = compute_overflow(bp_paths)
    best_cost = current_cost
    T = T0
    while T > 1:
        # 随机选择流向和操作(INSERT/REMOVE)
        flow = random.choice(flows)
        op = random.choice(['INSERT', 'REMOVE'])
        new_paths = apply_operation(bp_paths, flow, op)
        new_cost = compute_overflow(new_paths)
        delta = new_cost - current_cost
        if delta < 0 or random.random() < np.exp(-delta/T):

```



```

        bp_paths = new_paths
        current_cost = new_cost
        best_cost = min(best_cost, current_cost)
    T *= alpha
    return bp_paths, best_cost

```

1.3 问题三：设备投资优化核心代码

```

# 设备参数
EQUIPMENT = {
    'A': {'slots': 200, 'capacity': 60000, 'cost': 1500000},
    'B': {'slots': 300, 'capacity': 100000, 'cost': 2000000},
    'C': {'slots': 600, 'capacity': 200000, 'cost': 3400000},
    'D': {'slots': 100, 'capacity': 30000, 'cost': 950000},
}
DEPRECIATION_YEARS = 5
GROWTH_RATE = 0.20
MANUAL_COST_PER_SLOT = 18 # 元/格口/天

def greedy_equipment(node_info, design_volumes):
    """贪心设备配置"""
    # 按性价比排序: C > B > A > D
    equip_order = sorted(EQUIPMENT.keys(),
                          key=lambda k: EQUIPMENT[k]['slots'] /
                                          (EQUIPMENT[k]['cost']/DEPRECIATION_YEARS),
                          reverse=True)
    plan = {}
    for node_id, info in node_info.items():
        gap = info['slots_needed'] - info['G_i']
        if gap <= 0:
            continue
        node_plan = {}
        for etype in equip_order:
            while gap > EQUIPMENT[etype]['slots'] * 0.5:
                node_plan[etype] = node_plan.get(etype, 0) + 1
                gap -= EQUIPMENT[etype]['slots']
        # 剩余缺口用人工补充
        if gap > 0:
            manual_annual = gap * MANUAL_COST_PER_SLOT * 365
            min_equip_annual = min(
                e['cost']/DEPRECIATION_YEARS for e in EQUIPMENT.values
            )
            if manual_annual < min_equip_annual:

```

```
        pass # 人工更经济
    else:
        node_plan['D'] = node_plan.get('D', 0) + 1
    if node_plan:
        plan[node_id] = node_plan
    return plan
```

Modex Agnet